Stanje	Završeno
Započeto	ponedjeljak, 9. veljače 2026., 14:41
Završeno	ponedjeljak, 9. veljače 2026., 15:55
Utrošeno vrijeme	1 sat 13 min

Pitanje 1

Završeno

Što razlikuje funkciju jezgre koja zadovoljava Mercerov teorem od ostalih funkcija jezgre koje ga ne zadovoljavaju?

Napomena: Priznat će se samo potpuno točan odgovor.

- [ ] a. Omogućuje mapiranje uzoraka u novi prostor značajki kako bi postali linearno odvojivi u novom prostoru značajki.
- [x] b. Omogućuje izračun skalarnih produkata u novom prostoru značajki bez eksplicitnog mapiranja u novi prostor značajki.
- [ ] c. Omogućuje mapiranje uzoraka u novi prostor značajki kako bi postali linearno odvojivi u izvornom prostoru značajki.
- [x] d. Omogućuje izračun polinomskih kombinacija izvornih značajki.

Pitanje 2

Završeno

Koje tvrdnje vrijede za duboke unaprijedne neuronske mreže koje se uče metodom povratne propagacije greške (*backpropagation*)?

Napomena: Priznat će se samo potpuno točan odgovor.

- [ ] a. Ako su sve pojedinačne težine < 1, gradijenti se ne mogu povećavati s propagacijom pogreške prema ulaznom sloju.
- [x] b. Leaky ReLu aktivacija ublažava nedostatak standardne ReLu aktivacije jer ima nenulti gradijent za negativne ulaze.
- [x] c. U slučaju sigmoidalne aktivacije, ako su neuroni često u zasićenju, postoji povećan rizik od pojave iščezavajućih gradijenata.
- [ ] d. Preskočne (skip) veze primarno služe za smanjenje problema pretreniranja.
- [ ] e. Klasični autoenkoder uči minimiziranjem pogreške između preslikanih značajki niže dimenzionalnosti i njihovih očekivanih vrijednosti.

Pitanje 3

Završeno

Želimo pohraniti iduće vektore pomoću Hopfieldove mreže:

$s1 = [1, 1, 1, 1]^T$

$s2 = [1, -1, 1, -1]^T$

$s3 = [1, 1, 1, -1]^T$

Zanemarite pragove u mreži.

Napomene: Zaokružite rezultate na dvije decimale.

a) (2 b) Odredite matricu težina mreže. *Priznat će se samo potpuno točna matrica.*

0	0.25	0.75	-0.25
0.25	0	0.25	0.25
0.75	0.25	0	-0.25
-0.25	0.25	-0.25	0

b) (1 b) Izračunajte energiju stanja $s2$.

-1

c) (1 b) Ispitajte stabilnost stanja $s1$. *Upišite broj 1 ako je stanje stabilno, a broj 0 ako je stanje nestabilno.*

0

d) (3 b) Na koje sve načine stanje $[-1, 1, -1, 1]^T$ može prijeći u jedno od stabilnih stanja mreže? *Priznat će se samo potpuno točan odgovor.*

Unesite redne brojeve točnih tvrdnji bez razmaka uzlaznim redoslijedom., npr. stavljate 24 ako su tvrdnje 2 i 4 točne.

1) Navedeno stanje je već stabilno

2) U jednoj iteraciji asinkronog prijelaza

3) Sinkronim prijelazom

4) Ništa od navedenog

Rješenje: 2

Pitanje 4

Završeno

A) Ulaz mreže je slika dimenzije 64×64 (visina $\times$ širina) s tri kanala. Prvi konvolucijski sloj sadrži 7 filtara dimenzije 5×5 uz očuvanje dimenzija ulaza u sloj. Drugi sloj sadrži sažimanje maksimumom veličine 3×3 uz korak pomaka 2 po širini i visini ulaza u sloj (prozor mora biti u cijelosti unutar ulazne slike u sloj). Treći sloj je *flatten* sloj na koji se nadovezuje izlazni potpuno povezani sloj s 128 neurona. Zanemarite pragove u mreži.

(0.5 b) Koliko parametara za treniranje ima prvi konvolucijski sloj?

525

(0.5 b) Koja je visina mape značajki nakon prolaska kroz sloj sažimanjem.

31

(1 b) Koliko parametara za treniranje ima posljednji, potpuno povezani sloj?

861056

B) Pretpostavimo da na ulaz te mreže dovodimo video (niz slika) od 32 slike, te pretpostavite da se mreža koristi kao ekstraktor značajki. Potom se značajke za cijeli niz slika predaje direktno (bez transformacije, uz dodavanje pozicijskog kodiranja) transformatorskoj mreži s jednom glavom pažnje (unutar Multi-head self-attention bloka), vektorima upita *Q* veličine 48, vektorima ključa *K* veličine 48, te vektorima vrijednosti *V* veličine 64. Konačni izlaz mreže dobije se tako da se izlazi MSHA bloka usrednje te predaju potpuno povezanom sloju sa 16 neurona. Zanemarite pragove u mreži.

(1 b) Koliko ukupno parametara imaju učene matrice projekcije W_Q, W_K i W_V korištene za računanje vektora upita *Q*, ključa *K* i vrijednosti *V*?

25600

(1 b) Koliko stupaca ima matrica pažnje dobivena korištenjem *Q* i *K* vektora?

32

Pitanje 5

Završeno

Koje tvrdnje vrijede za klasičnu rekurzivnu neuronsku mrežu (RNN)?

Napomena: Priznat će se samo potpuno točan odgovor.

- [ ] a. Treniranje i izvođenje se može potpuno paralelizirati po vremenskoj osi.
- [ ] b. Vrijeme treniranja i izvođenja raste linearno s duljinom ulaznog niza.
- [x] c. Nema probleme iščezavanja i eksplozije gradijenata.
- [x] d. Skriveno stanje RNN-a ima fiksnu dimenziju.

Pitanje 6

Završeno

Kod klasične Hopfieldove mreže s proizvoljnim brojem neurona N, vrijedi da je preslušavanje zanemarivo kada je broj memoriranih uzoraka jednak N.

- (●) Točno
- ( ) Netočno

Pitanje 7

Završeno

Označite **ne**točne tvrdnje.

Napomena: Priznat će se samo potpuno točan odgovor.

- [ ] a. Kompetitivno učenje pripada učenju bez nadzora.
- [x] b. Kod Hebbovog učenja svaka ploha pogreške ima samo jedan minimum.
- [x] c. Učenje korekcijom pogreške pripada učenju bez nadzora.
- [ ] d. Kod učenja podrškom učitelj uspoređuje izlaz mreže i očekivani izlaz.

Pitanje 8

Završeno

Razmatramo jedan neuron s jednodimenzionalnim ulazom i izlazom.

Signal iznosa 2 doveden je na ulaz neurona čija je početna težina jednaka 0.9 i čija aktivacijska funkcija je identiteta $\phi(v) = v$. Stopa učenja iznosi 0.2. Izračunajte promjenu težine nakon jednog koraka učenja pomoću:

Napomena: Koristite zaokruživanje na dvije decimale.

a) (1 b) osnovnog Hebbovog pravila

$\Delta\omega =$ 0

b) (1 b) generaliziranog pravila produkta aktivnosti (modificiranog Hebbovog pravila) sa $c = \eta/\alpha = 0.15$.

$\Delta\omega =$ 0

Pitanje 9

Završeno

Promatramo skup podataka od 1000 uzoraka. Za svaki uzorak su dostupne vrijednosti četiri različite značajke. Za smanjivanje prostora značajki na dvodimenzionalni prostor primjenjujemo analizu glavnih komponenti (PCA). Već su izračunati normalizirani vlastiti vektori matrice kovarijance ulaznih podataka s pripadajućim vlastitim vrijednostima.

$v_1 = [-0.77, 0.36, -0.47, -0.23]^T; \lambda_1 = 40.1$
$v_2 = [-0.45, 0.06, 0.84, -0.29]^T; \lambda_2 = 95.2$
$v_3 = [0.20, -0.41, -0.22, -0.86]^T; \lambda_3 = 180.5$
$v_4 = [-0.40, -0.83, -0.16, 0.35]^T; \lambda_4 = 12.7$

a) (0.5 b) Koji od zadanih vlastitih vektora čine bazu novog reduciranog prostora značajki? *Ako je vektor dio te baze unesite 1, ako nije unesite 0. Priznat će se samo potpuno točno rješenje.*

v_1 0

v_2 1

v_3 1

v_4 0

b) (2 b) Ako je početni normalizirani uzorak $x = [8.30, -2.10, 1.75, -6.40]^T$, izračunajte njegovu projekciju u transformiranom dvodimenzionalnom prostoru. *Koristite zaokruživanje na tri decimale. Priznat će se samo potpuno točno rješenje.*

x_{proj} =[7.640 , -0.535]

Pitanje 10

Završeno

Promatramo grupiranje standardnim kompetitivnim učenjem koje koristi euklidsku udaljenost. Mreža se sastoji od dva neurona s početnim dvodimenzionalnim vektorima težina: $w_1 = [0.5, 0.5]$ i $w_2 = [5, 5]$. Stopa učenja iznosi 0.4.

Napomena: Koristite zaokruživanje na 4 decimale.

a) (1 b) Na ulaz mreže dovodimo uzorak $x_1 = [2, 2.3]$ i potom ažuriramo težine neurona. Odredite iznos ažuriranih težina. *Priznat će se samo potpuno točno rješenje.*

w_1 =[1 , 1]

w_2 =[1 , 1]

b) (1 b) Zatim na ulaz mreže dovodimo novi uzorak $x_2 = [3, 3.3]$ i ponovno ažuriramo težine neurona. Odredite iznos ažuriranih težina. *Priznat će se samo potpuno točno rješenje.*

w_1 =[1 , 1]

w_2 =[1 , 1]

c) (1.5 b) Koliko iznosi kvaliteta grupiranja (odnosno kvadratna greška) nakon provedenih ažuriranja, za dosadašnja dva uzorka?

5.123123

Pitanje 11

Završeno

Razmatramo jednoslojni perceptron s aktivacijskom funkcijom tipa prag.

Početne težine su $w_1 = 0.6$ i $w_2 = -0.1$ te prag $\theta = 0.3$. Težine se uče primjenom delta pravila učenja.

Odredite nove vrijednosti težina nakon prvog koraka učenja algoritma ako je ulazni vektor $x = [0.2, 1]$, očekivani izlaz 1 te stopa učenja $\eta = 0.4$.

Prag neurona možemo prikazati kao dodatni ulaz s fiksnim iznosom -1 i pripadnom težinom θ.

a) (1 b)

$w_1 =$ 0.6034406

b) (1 b)

$w_2 =$ -0.0827968