

Zahvaljujem svojoj obitelji i svima ostalima koji su bili uz mene.

Mentoru na vodstvu i savjetima tokom pisanja rada.

Sažetak

Implementacija središnjeg sustava za nadzor i vizualizaciju komunikacijskih obrazaca lokalne mreže

Ante Čavar

Mala poduzeća danas nemaju konkretan plan obrane od napada na svoju unutarnju mrežu, što uvelike ugrožava njihov opstanak i daljnji rad. Ovaj rad nudi mogućnost malim poduzećima i fizičkim osobama da bez velikih financijskih troškova i skupog sklopovlja brane i nadziru svoju lokalnu mrežu kao i ponašanje uređaja u toj mreži. Sustav omogućuje nadzor i evidenciju mrežnog prometa, vizualizaciju toka podataka u mreži i odgovor na najčešće prijetnje. Najzahtjevniji dio, postavljanje sustava, sada se provodi samo jednom te daljnji rad sustava ne predstavlja akumulirajući trošak, što uvelike pomaže onima kojima je potrebno jednostavno, samoodrživo i prenosivo rješenje za sigurnost lokalne mreže. Rješenje je lako izmjenjivo, što znači da se rad može prilagoditi različitim okruženjima i potrebama korisnika te se time izdvaja od već gotovih i poznatih rješenja.

Ključne riječi: Lokalna mreža, Zeek, mrežni obrasci, Docker, IDS, InfluxDB, Elasticsearch

Abstract

Implementation of a centralized system for monitoring and visualizing local network communication patterns

Ante Čavar

Small businesses today lack a concrete plan for defending against attacks on their internal network, which significantly threatens their survival and continued operation. This work offers small businesses and private individuals the ability to defend and monitor their local network, as well as the behavior of the devices within it, without large financial costs or expensive hardware. The system enables the monitoring and logging of network traffic, the visualization of data flow within the network, and a response to the most common threats. The most demanding part, setting up the system, is performed only once, so the system's ongoing operation does not constitute an accumulating cost — which greatly benefits those who need a simple, self-sustaining, and portable solution for local-network security. The solution is easily modifiable, meaning it can be adapted to different environments and user needs, thereby setting it apart from existing, well-known solutions.

Keywords: Local network, Zeek, network patterns, Docker, IDS, InfluxDB, Elasticsearch

Sadržaj

Sažetak	
Abstract	
1. Uvod	1
2. Teorijska podloga i tehnološki stog	2
2.1. Mrežna infrastruktura i pristupne točke	2
2.2. Sustavi za detekciju upada i analizu prometa	3
2.3. Kontejnerizacija mrežnih servisa	4
2.4. Pohrana vremenskih nizova i vizualizacija	4
3. Arhitektura	7
3.1. Pregled sustava	7
3.2. Usmjeravanje, NAT i pristupna točka	8
3.3. Pasivni nadzor i zapisivanje prometa Zeekom	9
3.4. Tok podataka i pohrana	10
3.5. Prepoznavanje i automatska reakcija	11
4. Implementacija	13
4.1. Postavljanje Docker okruženja	13
4.2. Konfiguracija mreže, NAT-a i pristupne točke	15
4.3. Konfiguracija Zeek senzora	17
4.4. Telegraf/InfluxDB i Filebeat/Elasticsearch	19
4.5. Grafana nadzorne ploče i usluživanje	20
4.6. Automatska reakcija: auto_reaction.py i nftables	21
4.7. Izazovi pri implementaciji	22
5. Evaluacija podsustava za pohranu	25
5.1. Metodologija usporedbe	25
5.2. Potrošnja prostora na disku	26
5.3. Potrošnja radne memorije	26

5.4. Kašnjenje upita	27
5.5. Rasprava rezultata	28
5.6. Zaključak usporedbe	28
6. Testiranje detekcije i automatske reakcije	30
6.1. Testno okruženje i metodologija	30
6.2. Provjera toka podataka	31
6.3. Testiranje detekcije	32
6.3.1. Skeniranje portova	32
6.3.2. Bruteforce SSH prijave	32
6.3.3. Podudaranje s pokazateljem kompromitacije	33
6.4. Testiranje automatske reakcije	34
6.4.1. Blokiranje izvora i istek blokade	34
6.4.2. Zaštita vlastite infrastrukture popisom dopuštenih adresa	35
6.5. Ograničenja uočena testiranjem	35
6.5.1. Lažiranje izvorišne adrese	35
6.5.2. Otpornost na nasilni prekid skripte	36
6.5.3. Izloženost nadzornih servisa	36
7. Zaključak i smjernice za daljnji rad	37
Literatura	39
Skraćenice	41
Izjava o korištenju umjetne inteligencije	43

1. Uvod

Velik broj današnjih uređaja povezan je u neku mrežu, a velika većina njih pripada lokalnim mrežama - kućnima, poslovnima ili vojnim. Lokalne su mreže time postale sveprisutne, no njihova sigurnost nije pratila brzinu razvoja i pristupačnosti tih istih mreža. Tek nakon niza sigurnosnih incidenata počinje rasti svijest poslovnih i privatnih korisnika o potrebi za zaštitom.

Kako bi se incidenti, a posljedično i troškovi za poslovne korisnike, smanjili, na tržištu se pojavilo mnoštvo programskih rješenja [1] [2], pa i zasebnih zanimanja poput analitičara u sigurnosno-operativnom centru (SOC). Takva su rješenja dostupna prije svega onima koji ih mogu platiti. Za neprekidan nadzor većim je organizacijama isplativo zaposliti tim analitičara raspoređenih u smjene. Postoje i automatizirana rješenja niže razine zaštite, no zajednički im je nedostatak cijena odnosno manjak resursa.

Cilj je ovog rada ponuditi programsko rješenje namijenjeno privatnim korisnicima i manjim tvrtkama, kojima visoki troškovi profesionalnih sustava predstavljaju prepreku koju veće organizacije lakše preskoče. U radu su razrađena i ispitana dva moguća rješenja navedenog problema. Kao temeljni alat za prikupljanje podataka korišten je Zeek, dok je analiza prikupljenih podataka provedena nad dvama podsustavima za pohranu - baza InfluxDB uz agenta Telegraf te baza Elasticsearch uz agenta Filebeat. U oba se slučaja prikupljeni podatci vizualiziraju u alatu Grafana.

Nakon opisa rješenja i postupka čitatelju se predstavljaju mogući smjerovi razvoja ovoga implementacijskog rješenja te daljnji koraci predviđeni za nastavak rada.

2. Teorijska podloga i tehnološki stog

Sigurnosni nadzor mreže (engl.*Network Security Monitoring* - *NSM*) predstavlja metodologiju prikupljanja, analize i eskalacije indikatora koji ukazuju na maliciozne aktivnosti unutar nekog mrežnog okruženja. Tradicionalni mehanizmi zaštite poput vatrozida i anti-virusa se fokusiraju na prevenciju napada izgradnjom barijera tj. statičke obrane. Usprkos tome, kako ističe Bejtlich [3], svaka obrana s vremenom zakaže zato što napadači stalno traže nove načine za zaobilazanje tih obrana - vječna igra mačke i miša. NSM se zato ne oslanja isključivo na spriječavanje i statičku obranu nego i na dubinsku vidljivost mrežnog prometa koja omogućava pravovremenu detekciju i reakciju odnosno aktivnu obranu za incidente.

Kako bi se uspostavio funkcionalan NSM sustav, potrebno je integrirati nekoliko različitih klasa alata: od mrežnih senzora za ekstrakciju metapodataka, preko optimiziranih baza podataka za pohranu vremenskih nizova, do grafičkih sučelja za vizualizaciju anomalija. U nastavku ovog poglavlja bit će opisane teorijske osnove tehnologija koje su odabrane kao temelj za izgradnju takvog rješenja.

2.1. Mrežna infrastruktura i pristupne točke

AP (engl.*Access Point*) još znano i kao pristupna točka je uređaj koji se ponaša kao most (engl.*bridge*) i time dopušta bežičnim uređajima poput laptopa, mobitela, IoT senzora da se povežu sa žičanom lokalnom mrežom (LAN). Za razliku od bežičnih rutera koji u sebi kombiniraju preusmjeravanje, vatrozid i WiFi funkcionalnosti pristupne točke se fokusiraju u potpunosti na bežično povezivanje (iako se danas ta granica između pristupne točke i rutera sve manje primjećuje).

hostapd je alat na Linuxu s kojim se može izabrano bežično mrežno sučelje sustava pretvoriti u pristupnu točku [4] pod uvjetom da postoji još jedno mrežno sučelje (žičano ili mrežno) koje će služiti kao izlaz na Internet. Između ostalog hostapd nudi mogućnosti:

- nadzora pristupne točke preko IEEE 802.11 standarda
- autentifikacijske protokole poput IEEE 802.1X, WPA, WPA2, i WPA3

- može funkcionirati kao RADIUS Server/Klijent što je posebno bitno firmama i državnim ustanovama

Kako bi uređaji povezani na pristupnu točku mogli funkcionalno komunicirati, potrebno je osigurati mrežnu konfiguraciju i razlučivanje naziva. Ulogu pružanja tih servisa u sustavima s ograničenim resursima često preuzima alat `dnsmasq` [5]. Potrebno je naglasiti da `dnsmasq` ne obavlja izolaciju ili usmjeravanje mrežnog prometa (što je primarni zadatak vatrozida), već isključivo objedinjuje funkcionalnosti DNS prosljeđivača (engl. *DNS forwarder*) i DHCP poslužitelja. Prihvaća lokalne DNS upite te ih prosljeđuje vanjskim DNS poslužiteljima kako bi se imena (domene) prevela u odgovarajuće IP adrese. DHCP (engl. *Dynamic Host Configuration Protocol*) poslužitelj se brine da se svakom uređaju koji pristupa mreži dinamički dodijeli jedinstvena IP adresa, podmrežna maska i adresa zadanog usmjernika, čime se omogućava neometana komunikacija i izbjegavaju mrežne kolizije.

2.2. Sustavi za detekciju upada i analizu prometa

Zeek je platforma otvorenog koda namijenjena dubinskoj analizi mrežnog prometa. Za razliku od pristupa koji bilježe sirove pakete (Wireshark), Zeek za svaku promatranu vezu generira strukturirani transakcijski zapis (engl. *transaction log*) s metapodacima poput trajanja veze, broja prenesenih okteta i korištenog protokola. Format izlaznih zapisa moguće je prilagoditi, a analiza se provodi neovisno o veličini mreže.

Zeek posjeduje vlastiti skriptni jezik kojim se definiraju pravila detekcije i određuje koji se metapodatci izdvajaju iz prometa. Time se logika detekcije prilagođava specifičnostima nadzirane mreže bez izmjene jezgre sustava.

Zeek razvrstava zapise prema protokolu i vrsti zabilježene aktivnosti (`conn.log`, `dhcp.log`, `http.log`, `files.log`, `dns.log` i drugi). Uz zapise vezane uz pojedini protokol, okvir za obavijesti (engl. *notice*) bilježi posebne događaje u `notice.log`; u toj se datoteci nalaze specifični obrasci povezivanja ili ponašanja uređaja koje smo opisali skriptnim jezikom kako bi ih Zeek prepoznao.

Alternative poput Suricata primarno su orijentirane na detekciju temeljenu na potpisima (engl. *signature-based detection*). Sveobuhvatna rješenja poput Security Oniona, iako funkcionalna, zahtijevaju značajno više resursa tj. minimalno 12 GB RAM-a za minimalnu instalaciju [2] [6] — što ih čini neprikladnima za upogonjavanje na potrošačkom hardveru. Prednost Zeeka je u olakšanoj ekstrakciji metapodataka i svestranom skriptnom jeziku koji omogućava izradu vlastite detekcijske logike uz minimalni memorijski otisak.

2.3. Kontejnerizacija mrežnih servisa

Docker je platforma za razvoj, dijeljenje i pokretanje aplikacija. Omogućava odvajanje aplikacija od infrastrukture [7]. Kako bi to efikasno napravio, Docker koristi kontejnere.

Kontejneri su mala okruženja koja se pokreću na računalu domaćinu te su izolirana od ostalih procesa korištenjem *namespaceova* i *cgroups* tj. kontrolnih grupa. Kontejneri su pokretljive instance slika (engl.*images*) koje se mogu izraditi, pokrenuti, zaustaviti, premjestiti ili izbrisati pomoću Docker alata. Također su portabilni te se mogu pokrenuti lokalno, u virtualnim strojevima i u oblaku.

Docker se pobrinuo da kontejneri imaju minimalan utjecaj na domaćina te za pokretanje kontejnera nije potrebna instalacija dodatnih ovisnosti na sustavu domaćina. Svaki se kontejner pokreće u izoliranom okruženju te može komunicirati sa ostalim kontejnerima tek ako mu se to eksplicitno dozvoli.

Za orkestraciju više kontejnera koji zajedno čine jednu aplikaciju Docker nudi alat Docker Compose. Konfiguracija cijelog skupa servisa definira se u jednoj *docker-compose.yml* datoteci koja opisuje svaki servis, njegove ovisnosti, volumene i mrežne postavke. Pokretanje cijelog sustava svodi se na jednu naredbu `docker compose up -d`, što znatno pojednostavljuje upogonjavanje i reproducibilnost okruženja te je glavni razlog zašto je upravo Docker korišten u ovom radu.

2.4. Pohrana vremenskih nizova i vizualizacija

InfluxDB je baza podataka temeljena na modelu vremenskih nizova (engl.*time-series*), optimizirana za pohranu, indeksiranje i upite nad podacima kod kojih je vrijeme glavna organizacijska dimenzija [8]. Glavne karakteristike:

- indeksiranje temeljeno na vremenu
- pretežno *append*-orijentirana pohrana (optimizirana za velik broj sekvencijalnih upisa; uklanjanje podataka provodi se politikama zadržavanja (engl.*retention policy*), a ne pojedinačnim izmjenama)
- kompresija i smanjenje uzorkovanja (engl.*downsampling*) radi manjeg zauzeća prostora
- ugrađene agregacijske funkcije nad vremenskim intervalima (pomični prosjeci, percentili, sažetci)

InfluxDB 2.7 podržava dva jezika upita, Flux i InfluxQL. U ovom je radu korišten Flux. Flux

je funkcionalni skriptni jezik otvorenog koda za upite, analizu i obradu podataka vremenskih nizova te je izvorni jezik upita za InfluxDB 2.x [9] [10]. Za razliku od InfluxQL-a, sintakso bliskog SQL-u, Flux je kompozibilan i uz InfluxDB podržava i druge izvore podataka (primjerice PostgreSQL i BigQuery) te formate poput CSV-a i JSON-a.

Primjer Flux upita prikazan je u ispisu 2.1 [11].

```
import "influxdata/influxdb/v1"

option v = {bucket: "my-bucket", org: "my-org"}

from(bucket: v.bucket)
  |> range(start: -1h)
  |> filter(fn: (r) => r._measurement == "cpu")
  |> mean()
```

Kod 2.1. Primjer Flux upita

Upit 2.1 definira "kantu" informacija te se iz tog *bucketa* redom povlači informacije na sljedeći način: svi logovi iz prethodnih sat vremena (`start: -1h`), koji u sebi sadrže informaciju o CPU-u (`filter(fn: (r) => r._measurement == "cpu")`) te potom iz tih informacija izvlači srednja vrijednost (`mean()`). Drugim riječima ovaj upit će prikupiti informacije o CPU-u u zadnjih sat vremena te će prikazati njihovu srednju vrijednost.

Telegraf je agent za prikupljanje podataka otvorenog koda koji razvija InfluxData, a koji prikuplja, obrađuje i agregira metrike, logove i druge podatke iz različitih izvora. Služi kao primarni sloj za unos podataka za InfluxDB, bazu podataka vremenskih serija, koristeći arhitekturu temeljenu na dodacima s preko 300 ulaznih i izlaznih dodataka za prikupljanje podataka iz sustava, senzora i aplikacija te njihov izravan zapis u InfluxDB. [12] [13] Neke od karakteristika Telegrafa su:

- Arhitektura temeljena na dodacima (*pluginovi*) (korisnik konfigurira ulaze i izlaze u `telegraf.conf` što omogućuje fleksibilno upravljanje tokom podataka bez konkretnog znanja programiranja)
- Napisan u jeziku GO (jedna binarna datoteka s mogućnošću obrade ogromne količine podataka s više uređaja)
- Pretprocesiranje podataka (može očistiti, filtrirati i transformirati podatke prije nego što stignu do baze podataka)

Uz InfluxDB i Telegraf, kao alternativa ispitan je i Elasticsearch uz Filebeat kao agentom za prikupljanje podataka.

Elasticsearch je distribuirani sustav za pretraživanje i analizu podataka otvorenog koda temeljen na Apache Lucene biblioteci. [14] Za razliku od InfluxDB-a koji optimizira po-

hranu vremenskih serija, Elasticsearch tretira svaki zapis kao JSON dokument koji se indeksira kroz invertirani indeks (engl.*inverted*) index — struktura podataka koja omogućava brzu pretragu po sadržaju polja. Ta arhitektura čini Elasticsearch pogodnim za pretraživanje punim tekstom i korelaciju podataka iz heterogenih izvora, no dolazi s većim memorijskim i prostornim otiskom u usporedbi s InfluxDB-om što će biti detaljnije prikazano u poglavlju evaluacije.

Kao što Telegraf služi kao agent za unos podataka u InfluxDB, Filebeat preuzima analognu ulogu u Elasticsearch ekosustavu. [15] Filebeat je lagani agent koji prati zadane datoteke zapisnika i proslijeđuje nove zapise u Elasticsearch. U kontekstu ovog rada, Filebeat čita Zeekove JSON logove iz dijeljenog volumena i indeksira ih u Elasticsearch bez transformacije podataka.

Grafana je platforma otvorenog koda za vizualizaciju i analizu podataka koja podržava više od pedeset izvora podataka, uključujući InfluxDB i Elasticsearch. [16] Dashboardi se konfiguriraju kroz grafičko sučelje i mogu se izvesti kao JSON datoteke te pohraniti u repozitorij, što omogućava automatsko učitavanje pri pokretanju sustava (engl.*provisioning*). U ovom radu Grafana služi kao jedinstveno vizualizacijsko sučelje za oba ispitana backend rješenja.

3. Arhitektura


U ovom se poglavlju opisuje arhitektura predloženog (kasnije i implementiranog) sustava. Opisuje se način na koji je lokalna mreža usmjerena kroz pristupnu točku, gdje se i kako prikuplja mrežni promet te kako se prikupljeni podatci pohranjuju, vizualiziraju te u konačnici kako se s tim podacima rukuje kako bi se postigla automatska detekcija. Naglasak je na odlukama o dizajnu i njihovim opravdanjima, dok se konkretna implementacija obrađuje kasnije.

3.1. Pregled sustava

Sustav je zamišljen da pretvori uređaj s mrežnim mogućnostima u jedinstvenu točku kroz koju prolazi sav promet lokalne mreže, čime se ostvaruje potpuna vidljivost komunikacije između lokalnih uređaja i vanjskih odredišta. Taj uređaj istovremeno obavlja funkciju usmjernika (engl. *gateway*), pristupne točke, mrežnog senzora i vatrozida. Ovakvom tipu posla najviše odgovara uređaj koji na sebi ima instaliran Linux, te iako su mogući i drugi načini oni se kroz rad ne istražuju.

Slika 3.1. prikazuje tok podataka kroz sustav. Sav mrežni promet prolazi kroz pristupnu točku gdje ga Zeek pasivno analizira i pohranjuje u obliku strukturiranih JSON zapisa u dijeljeni direktorij. Tom direktoriju dva različita podsustava imaju pristup, no ne istovremeno. Prvi podsustav čini vremenski orijentirana baza InfluxDB posredstvom podatkovnog agregatora Telegrafa. Drugi podsustav čini dokumentno orijentirana baza Elasticsearch posredstvom agenta zvanog Filebeat. Oba podsustava kao zajedničko vizualizacijsko sučelje koriste Grafanu. Implementacija dvaju podsustava ne predstavlja produkcijsku konfiguraciju, već služi za njihovu usporedbu opisanu u kasnijim poglavljima. U stvarnoj bi se primjeni odabrao jedan od njih ovisno o potrebama i mogućnostima.


Svi navedeni servisi izvode se u Docker kontejnerima, čime se postiže ponovljivost i prenosivost okruženja te jednostavnost pri postavljanju [7]. Jedina je iznimka skripta za automatsku reakciju, koja se izvodi izravno na domaćinu iz kasnije objašnjenih razloga.



Slika 3.1. Prikaz toka podataka kroz sustav

3.2. Usmjeravanje, NAT i pristupna točka

Mrežna topologija sustava može se iščitati sa slike 3.2.



Slika 3.2. Mrežna topologija

Uređaj (u ovom slučaju prijenosno računalo) koji objedinjuje uloge prikazane na slici 3.2. također mora posjedovati barem dva mrežna sučelja različitih namjena. *Ethernet* sučelje `enp2s0` povezano je na usmjernik odnosno infrastrukturu pružatelja internetskih usluga (engl. *Internet Service Provider - ISP*) i predstavlja izlaz za komunikaciju van lokalne mreže, odnosno predstavlja izlaz prema internetu. Moguće je iskoristiti i bežično umjesto žičanog sučelja, no ono je u pravilu nestabilnije. Bežično sučelje `wlan1` konfigurirano je kao pristupna točka pomoću alata `hostapd`, dok se razlučivanje imena (engl. *name resolution*) i postavljanje mrežnih parametara rješava uz pomoć `dnsmasq`. Bežični klijenti, odnosno ostali uređaji u mreži, pridružuju se mreži `10.0.1.0/24` u kojoj prethodno spomenuti uređaj s ulogom usmjernika ima adresu `10.0.1.1` što je inače konvencija pri postavljanju lokalnih

mreža [17]. Kako bi se izbjegli sukobi pri upravljanju bežičnim sučeljem, ono se mora prije konfiguracije pristupne točke izuzeti iz nadzora domaćinskog servisa NetworkManager koji inače upravlja mrežnim sučeljima na Linuxu.

Kako klijenti vanjskim mrežama pristupaju isključivo preko jedne točke, sav promet između unutarnjih uređaja i vanjskih izvorišta i odredišta nužno mora proći kroz uređaj čime se ostvaruje potpuna vidljivost prometa što je nužan preduvjet za analizu komunikacijskih obrazaca. Prosljeđivanje paketa omogućeno je postavljanjem sistemskog parametra `sysctl -w net.ipv4.ip_forward=1`, a prevođenje adresa (engl.*NAT*) ostvareno je pravilom maskiranja odlaznog prometa na žičanom sučelju prikazanim u ispisu 3.1

```
nft add table ip diplomski
nft add chain ip diplomski postrouting \
    { type nat hook postrouting priority 100 \; }
nft add rule ip diplomski postrouting ip saddr 10.0.1.0/24
    oifname enp2s0 masquerade
```

Kod 3.1. Maskiranje odlaznog prometa u nftables tablici

Upravljanje vatrozidom na uređaju temelji se na dva alata: `nftables` i `ufw`. Oba djeluju nad istom pozadinskom implementacijom. Na suvremenim se distribucijama i `ufw` izvodi kroz `nftables`, a starije `iptables` naredbe prevode se posredstvom sloja `iptables-nft`. `nftables` je zapravo jedini pozadinski mehanizam koji se koristi, dok se naredbe ostalih alata prevode kroz `nft`.

Vatrozid `ufw` (engl.*Uncomplicated Firewall*) provodi sigurnosne politike tj. pravila izravno na uređaju. Zadana postavljena politika vatrozida za `INPUT` i `FORWARD` lance je odbacivanje svog prometa, zbog čega se rad pristupne točke mora iznimno dopustiti. Dozvole za normalan rad pristupne točke provode se pravilima za DHCP promet na `wlan1` sučelju te pravilom za usmjeravanje prometa između prethodno spomenutih sučelja (bežično i žičano). Posljedica je takve politike i to da neželjeni dolazni internetski promet domaćin odbacuje već na temelju zadane politike, neovisno o ostalim slojevima. Pravilo prevođenja adresa izdvojeno je u zasebnu `nftables` tablicu kako bi se cjelokupna konfiguracija usmjeravanja mogla ukloniti jednom naredbom, bez utjecaja na ostatak sustava.

3.3. Pasivni nadzor i zapisivanje prometa Zeekom

Nadzorni sloj čini samo Zeek kojem je preko `docker-compose` datoteka dozvoljen pasivan pristup odnosno nadzor nad `wlan1` sučeljem. Za razliku od ostalih servisa, Zeek se ne izvodi u izoliranoj kontejnerskoj mreži, već koristi mrežu domaćina (engl.*host network mode*). Razlog je taj što senzor mora imati izravan pristup fizičkom sučelju `wlan1` radi osluškivanja prometa. Iz istog se razloga kontejneru dodjeljuju ovlasti `NET_ADMIN` i `NET_RAW`, koje mu omogućuju otvaranje "sirovih spojnih točaka" (engl.*raw sockets*) i hvatanje paketa

na razini sučelja. Ovdje je bitno objasniti da se pod spojne točke misli na mrežne spojne točke koje omogućavaju Zeeku čitanje podatkovnog i mrežnog sloja (L2 i L3 slojevi).

Nadalje, odabir sučelja wlan1 kao mjesta nadzora nije proizvoljan. Snimanjem na wlan1, prije maskiranja, izvorišne i odredišne adrese ostaju nepromijenjene (primjerice 10.0.1.43), čime se zadržava atribucija po uređaju što je nužno za pravilnu analizu. Nije isto ako stolno računalo ili pametni hladnjak pokreću SSH i FTP veze.

Zeek prepoznaje i prati mnoštvo mrežnih protokola te o njihovoj aktivnosti vodi strukturirane zapise koje razvrstava u zasebne datoteke prema vrsti zabilježene aktivnosti i pohranjuje u direktorij zeek-logs. Među njima su, primjerice, conn.log, dns.log, dhcp.log, http.log, ssh.log, files.log, quic.log i notice.log. Većina je zapisa vezana uz pojedini protokol, dok pojedini bilježe izvedene događaje neovisno o protokolu. Najvažniji je takav zapis notice.log, u koji Zeek upisuje upozorenja na temelju kojih se pokreće automatska reakcija opisana kasnije u ovom poglavlju. Sljedeći važan zapis je conn.log koji u sebi nosi sav ostali promet (TCP, UDP...). Kratki opis ostalih zapisa:

- dns.log - zapisuje sve DNS upite
- dhcp.log - zapisuje klijente te informacije o njihovim IP adresama, MAC-ovima, nazivima...
- http.log - zapisuje sve HTTP zahtjeve zato što su nešifrirani i bogati metapodacima
- ssh.log - zapisuje sve SSH veze
- files.log - sve datoteke koje su izlazile prema vanjskom i ulazile na unutarnje sučelje
- quic.log - zapis o brzim UDP vezama (engl. *Quick UDP Internet Connections*)

Zapisi se generiraju u JSON formatu, čime se omogućuje njihovo izravno strojno čitanje bez dodatne pretvorbe. Time direktorij zeek-logs postaje jedinstvena predajna točka prema podsustavima za pohranu, opisanima u nastavku.

3.4. Tok podataka i pohrana

Zeekovi zapisi iz direktorija zeek-logs su ulazna točka za pohranu, kako je prikazano na slici 3.1. Taj je direktorij u kontejneru senzora montiran s pravom pisanja, a u agente za prikupljanje isključivo s pravom čitanja. Time se prikupljanje odvaja od pohrane.

Nad istim se zapisima ispituju dva podsustava za pohranu. Prvi čini agent Telegraf, koji Zeekove JSON zapise upisuje u vremenski orijentiranu bazu InfluxDB. Drugi čini agent Fi-

lebeat, koji iste zapise prosljeđuje u dokumentno orijentiranu bazu Elasticsearch. Uloge i svojstva pojedinih alata detaljnije su opisani u prethodnom poglavlju o teorijskim osnovama.

Ta dva podsustava nisu predviđena za istovremeni rad. Definirani su u zasebnim docker-compose datotekama, pri čemu svaka konfiguracija sadrži vlastiti senzor i vlastitu instancu Grafane, pa se u danom trenutku izvodi isključivo jedna. Razdvajanje ima dva cilja. Prvo, izolacija sprječava da trošenje resursa jednog podsustava iskrivi mjerenja drugoga, što je preduvjet poštene usporedbe provedene u poglavlju evaluacije. Drugo, budući da obje konfiguracije kao ulaz koriste isti skup Zeekovih zapisa istoga formata, razlike u rezultatima moguće je pripisati isključivo pozadinskoj bazi, a ne ulaznim podacima.

Objekt konfiguracije koristi Grafanu kao vizualizacijsko sučelje, čime se uklanja i utjecaj načina prikaza na rezultate. Postojanje obje konfiguracije stoga ne predstavlja produkcijsko rješenje, već isključivo sredstvo njihove usporedbe. U stvarnoj bi se primjeni odabrala jedna, ovisno o potrebama i mogućnostima.

3.5. Prepoznavanje i automatska reakcija

Prepoznavanje i automatska reakcija događa se u dva koraka. Najprije Zeek uočava problem odnosno prepoznaje kada je neka veza sumnjiva. Podrazumijevano, Zeek ne prepoznaje maliciozne veze, no dolazi sa povećim brojem već gotovih "skenera", protokola i okvira koji je moguće konfigurirati kroz `local.zeek` datoteku. Primjer njihovog učitavanja prikazan je u ispisu 3.2

```
@load base/protocols/conn
@load base/protocols/dns
@load base/protocols/http
@load base/protocols/ssl
@load base/frameworks/notice
```

Kod 3.2. Primjer učitavanja dodataka u `local.zeek`

Učitavanje dodataka omogućava Zeeku da prati više toga što omogućava veći izvor informacija. Osim toga unutar `intel.dat` datoteke (ali i kroz Zeekov skriptni jezik direktno u `local.zeek`) moguće je definirati pokazatelje kompromisa (engl. *Indicators of Compromise (IoC)*). Format `intel.dat` datoteke je osjetljiv na tabove i zato je dobro za bitne obavijesti imati i skriptu napisanu u `local.zeek` [18]. Kao što je prije spomenuto te obavijesti se spremaju u `notice.log`.

Skripta za automatsku reakciju `auto_reaction.py` napisana je u Pythonu i ne zahtijeva preuzimanje dodatnih paketa. Ona cijelo vrijeme gleda zadnji redak `notice.log` datoteke te na temelju njega provodi blokiranje izvorišnih adresa. Pokreće se s administratorskim ovlastima jer mijenja vatrozidna pravila domaćina.

Blokiranje je izvedeno preko skupa (engl.*set*) denylist unutar `nftables` tablice diplomatski. Skripta detektirane adrese dodaje kao elemente tog skupa, dok zasebni lanci na `forward` i `input` kukama (engl.*hooks*) odbacuju sav promet čija se izvorišna adresa nalazi u skupu. Ti su lanci na nižem brojevnom prioritetu (višem hijerarhijskom) od `ufw`-ovih, čime odbacivanje stupa na snagu prije nego što ostala pravila propuste vezu. Adrese usmjernika i lokalnog domaćina izuzete su popisom dopuštenih adresa (engl.*whitelist*) kako bi se spriječilo blokiranje vlastite infrastrukture.

Nadalje, valja istaknuti i ograničenje samog pristupa, odnosno reakcija se temelji na izvorišnoj adresi iz zapisa upozorenja. U slučaju lažiranja izvorišne adrese (engl.*spoofing*) skripta blokira adresu navedenu u zapisu, koja ne mora odgovarati stvarnom napadaču. To znači da napadač može lažirati adresu legitimnog korisnika odnosno uređaja. Kako bi se to izbjeglo predlaže se stalno ažuriranje popisa dopuštenih adresa uređajima kojima se vjeruje kao i dodjela statičkih adresa uređajima od povjerenja. Naravno bitno je za naglasiti da to i dalje ne sprječava napadača u potpunosti, no bolji pristupi se neće ovdje razmatrati jer to nije cilj ovog rada.

Svaki element prethodno navedenog skupa nosi vremensko ograničenje (engl.*timeout*) kojim upravlja jezgra operacijskog sustava, pa se pravilo uklanja automatski nakon isteka, bez ikakve intervencije korisnika ili skripte. Time se izbjegava slabost izvedbe zasnovane na izravnim pravilima. Ukratko to znači da nasilni prekid skripte (signalom `SIGKILL`, nedostatkom memorije ili gubitkom napajanja) ne ostavlja zaostala pravila jer ona ionako isteknu sama, a cjelokupno se stanje uklanja jednom naredbom brisanja tablice.

4. Implementacija

4.1. Postavljanje Docker okruženja

Svi servisi sustava, osim skripte za automatsku reakciju, izvode se u Docker kontejnerima [7]. Napisane su dvije `docker-compose` datoteke, jedna za svaki od dvaju ispitana podsustava. `docker-compose.yml` opisuje podsustav s bazom InfluxDB i agentom Telegraf, dok `docker-compose-elk.yml` opisuje podustav s bazom Elasticsearch i agentom Filebeat. Obje konfiguracije dijele isti Zeek senzor i istu inačicu Grafane. Budući da oba podsustava koriste kontejner istog imena (`zeek-ids`) i isti ulaz (3000 za Grafanu), istovremeno pokretanje nije moguće, odnosno u bilo kojem danom trenutku se može izvoditi samo jedan podsustav, što je ujedno i preduvjet za poštenu usporedbu u kasnijem poglavlju evaluacije.

Osjetljivi parametri poput korisničkih imena, lozinki, pristupnih tokena te naziva organizacije i spremnika (engl.*bucket*) — izdvojeni su iz `docker-compose` datoteka u zasebnu `.env` datoteku okruženja, čime se konfiguracija odvaja od tajni što je standardna praksa. Struktura datoteke `.env` prikazana je u ispisu 4.1

```
INFLUXDB_USER=admin
INFLUXDB_PASSWORD=<lozinka>
INFLUXDB_ORG=dipl
INFLUXDB_BUCKET=zeek-logs
INFLUXDB_TOKEN=<token>

GRAFANA_USER=admin
GRAFANA_PASSWORD=<lozinka>
```

Kod 4.1. Struktura `.env` datoteke (lozinke i pristupni tokeni skriveni)

Pri prvom pokretanju InfluxDB se inicijalizira automatski putem varijabli `DOCKER_INFLUXDB_INIT_*` u `setup` načinu rada 4.2, što omogućuje da se bez ručne intervencije stvaraju korisnik, organizacija, spremnik i administratorski token. Time se izbjegava ručno postavljanje baze nakon svakog ponovnog pokretanja, što je veoma bitno za ponovljivost i održivost okruženja.

```
environment:
  - DOCKER_INFLUXDB_INIT_MODE=setup
  - DOCKER_INFLUXDB_INIT_USERNAME=${INFLUXDB_USER}
  - DOCKER_INFLUXDB_INIT_PASSWORD=${INFLUXDB_PASSWORD}
```

```
- DOCKER_INFLUXDB_INIT_ORG=${INFLUXDB_ORG}
- DOCKER_INFLUXDB_INIT_BUCKET=${INFLUXDB_BUCKET}
- DOCKER_INFLUXDB_INIT_ADMIN_TOKEN=${INFLUXDB_TOKEN}
```

Kod 4.2. Automatska inicijalizacija InfluxDB okruženja iz `docker-compose.yml`

Isti se token prosljeđuje Grafani kroz okolišnu varijablu kako bi se izvor podataka konfigurirao automatski pri pokretanju (engl. *provisioning*), bez ručnog unosa pristupnih podataka u sučelju kao što je vidljivo u ispisu 4.3

```
environment:
- GF_SECURITY_ADMIN_USER=${GRAFANA_USER}
- GF_SECURITY_ADMIN_PASSWORD=${GRAFANA_PASSWORD}
- GF_USERS_ALLOW_SIGN_UP=false
# Prosljeđuje token u provisioning YAML putem env varijable
- INFLUXDB_TOKEN=${INFLUXDB_TOKEN}
- INFLUXDB_ORG=${INFLUXDB_ORG}
- INFLUXDB_BUCKET=${INFLUXDB_BUCKET}
```

Kod 4.3. Automatska inicijalizacija Grafane okruženja iz `docker-compose.yml`

Cjelokupno pokretanje, zaustavljanje i nadzor okruženja centralizira skripta `dipl.sh`, koja povezuje postavljanje pristupne točke i pokretanje kontejnera u jednu cjelinu. Postavljanje se provodi korak po korak. Ako pokretanje kontejnera ne uspije, prethodno postavljena mrežna konfiguracija automatski se poništava 4.4, čime se izbjegava ostavljanje sustava u polupostavljenom stanju u kojem je pristupna točka aktivna, a nadzor nije.

```
if [ "$1" == "start" ]; then
echo -e "${YELLOW}[1/2] Postavljanje AP okoline...${NC}"
bash "$NET_SCRIPT" set
if [ $? -ne 0 ]; then
echo -e "${RED}Greska pri postavljanju AP-a. Prekidam.${NC}"
exit 1
fi
echo -e "${GREEN}AP okolina postavljena.${NC}"
echo -e "${YELLOW}[2/2] Pokretanje Docker servisa...${NC}"
docker compose -f "$SCRIPT_DIR/docker-compose.yml" up -d
if [ $? -ne 0 ]; then
echo -e "${RED}Greska pri pokretanju Docker servisa.
Resetiram AP...${NC}"
bash "$NET_SCRIPT" reset
exit 1
fi
fi
```

Kod 4.4. Atomarno pokretanje u `dipl.sh` (naredba `start`)

Naredbe `stop`, `restart` i `status` upravljaju gašenjem, ponovnim pokretanjem i prikazom stanja servisa na sljedeći način: `sudo ./dipl.sh <naredba>`.

4.2. Konfiguracija mreže, NAT-a i pristupne točke

Potrebna mrežna konfiguracija postavlja se skriptom `net_setReset_rules.sh`, koja prima argument `set` ili `reset`. Uređaj raspolaže dvama sučeljima - žičanim `enp2s0` prema pružatelju internetskih usluga i bežičnim `wlan1` u ulazi pristupne točke s adresom `10.0.1.1`. Bežično sučelje u ulazi pristupne točke ostvareno je USB bežičnim mrežnim prilagodnikom TP-Link TL-WN722N inačica v1.

Za rad u načinu pristupne točke prilagodnik mora zadovoljiti dva uvjeta. Njegov *chipset* mora podržavati (engl.*master*) (AP) način rada, a pripadni upravljački program mora biti dostupan kroz `nl80211` sučelje kojim `hostapd` upravlja prilagodnikom. Poželjno je i da je upravljački program dio jezgre čime se izbjegava oslanjanje na vanjske, neslužbene upravljačke programe.

Inačica v1 zadovoljava sve navedeno. Temelji se na *chipsetu* Atheros AR9271 s upravljačkim programom `ath9k_htc`, koji je dio jezgre i izvorno podržava način pristupne točke [19]. Kasnije inačice (v2 i v3) koriste *chipset* Realtek RTL8188EUS, za koji podrška za način pristupne točke nije pouzdano dostupna kroz jezgru, već zahtijeva ručno postavljanje neslužbenih upravljačkih programa. Stoga je upravo inačica v1 prikladna za ovu primjenu bez dodatnih zahvata.

Sučelje `wlan1` najprije se izuzima iz nadzora servisa `NetworkManager`, nakon čega mu se ručno dodjeljuje adresa i omogućuje prosljeđivanje paketa kao što je vidljivo 4.5 Izuzimanje je nužno jer bi `NetworkManager` inače pokušao samostalno upravljati sučeljem i ulazio u sukob s `hostapd`-om koji isto sučelje postavlja u način rada pristupne točke.

```
nmcli device set wlan1 managed no
ip link set wlan1 down
ip link set wlan1 up
ip addr add 10.0.1.1/24 dev wlan1
sysctl -w net.ipv4.ip_forward=1
```

Kod 4.5. Izuzimanje sučelja i omogućavanje usmjeravanja

Konfiguracija vatrozida i prevođenja adresa smještena su u zasebnu `nftables` tablicu `diplomski`, što omogućuje uklanjanje postavki jednom naredbom bez utjecaja na ostatak sustava. Tablica sadrži pravilo maskiranja (engl.*NAT*) odlaznog prometa podmreže `10.0.1.0/24` na sučelju `enp2s0`, prikazano u ranijem ispisu 3.1

Uz pravilo maskiranja, ista tablica unaprijed priprema infrastrukturu za automatsku reakciju pomoću skupa `denylist` s vremenskim ograničenjem trajanja članova te dva lanca koja odbacuju promet izvorišnih adresa iz tog skupa na `forward` i `input` kukama (engl.*hooks*) `reflst:denylist`. Lanci su postavljeni na prioritet `-10`, niži (a time hijerarhijski viši) od zadanih `ufw` lanaca, pa odbacivanje stupa na snagu prije ostalih pravila. Struktura blokade definira

se ovdje, jednom, dok skripta za reakciju opisana u kasnijoj sekciji samo dodaje adrese u postojeći skup.

```
nft add set ip diplomski denylist { type ipv4_addr ; flags
    timeout ; timeout 30s ; }

nft add chain ip diplomski drop_fwd { type filter hook forward
    priority -10 ; }
nft add rule ip diplomski drop_fwd ip saddr @denylist drop
nft add chain ip diplomski drop_in { type filter hook input
    priority -10 ; }
nft add rule ip diplomski drop_in ip saddr @denylist drop
```

Kod 4.6. denylist i lanci za odbacivanje prometa

Originalna politika vatrozida ufw odbacuje sav promet, pa se rad pristupne točke iznimkom dopušta najmanjim potrebnim skupom pravila 4.7 odnosno DHCP promet na ulazima 67 i 68 te usmjeravanje s wlan1 na enp2s0. Posljedica te je politike da će se dolazni neželjeni internetski promet odbaciti neovisno o ostalim slojevima.

```
ufw allow in on wlan1 to any port 67 proto udp
ufw allow in on wlan1 to any port 68 proto udp
ufw route allow in on wlan1 out on enp2s0
```

Kod 4.7. Dopuštenja ufw za rad pristupne točke

Bežična pristupna točka realizirana je alatom hostapd [4] na sučelju wlan1, uz zaštitu WPA2-PSK sa CCMP protokolom 4.8 Ključna je postavka ap_isolate=0 kojom se omogućuje izolacija klijenata. Pristupne točke uobičajeno izoliraju klijente kako međusobno ne bi komunicirali, no tada njihov međusobni promet ne bi prolazio kroz točku nadzora; isključivanjem izolacije Zeek dobiva vidljivost i nad istok-zapad prometom unutar lokalne mreže.

```
interface=wlan1
ssid=Dipl_test_FORBIDDEN
hw_mode=g
channel=6
wpa=2
wpa_key_mgmt=WPA-PSK
rsn_pairwise=CCMP
wpa_passphrase=<lozinka>
ap_isolate=0
```

Kod 4.8. Bitne postavke hostapd konfiguracije

Mrežne parametre postavlja dnsmasq [5] 4.9 tako da klijentima na sučelju wlan1 dodjeljuje adrese iz raspona 10.0.1.10–10.0.1.100, zadaje usmjernik 10.0.1.1 te adrese vanjskih DNS poslužitelja 8.8.8.8 i 1.1.1.1. U ovoj konfiguraciji dnsmasq djeluje isključivo kao DHCP poslužitelj, dok se prevođenje adresa povjerava izravno vanjskim poslužiteljima, bez lokalnog prosljeđivanja. Time se ne gubi nadzor nad DNS prometom, unatoč tome da

su odredišni DNS poslužitelji izvan lokalne mreže, upiti svejedno prolaze kroz usmjernik i sučelje wlan1, gdje ih Zeek bilježi i pridodaje pojedinom klijentu odnosno uređaju. Ova vidljivost vrijedi za klasične DNS upite preko UDP/53; klijenti koji koriste šifrirani DNS (DoH ili DoT) zaobilaze je jer Zeek takve upite vidi tek kao TLS odnosno QUIC promet prema vanjskom poslužitelju. Korišteni adresni prostor 10.0.1.0/24 dio je raspona 10.0.0.0/8 rezerviranog za privatne mreže prema RFC-u 1918 [17], dok dodjela adrese s završetkom .1 usmjerniku slijedi uobičajenu, premda nestandardiziranu, praksu pri postavljanju lokalnih mreža.

```
interface=wlan1
dhcp-range=10.0.1.10,10.0.1.100,255.255.255.0,24h
dhcp-option=option:router,10.0.1.1
dhcp-option=option:dns-server,8.8.8.8,1.1.1.1
```

Kod 4.9. Postavke DHCP-a i DNS prosljeđivanja u dnsmasq

Naredbom `sudo ./dipl.sh stop` u glavnom direktoriju cijela se konfiguracija poništava. Gase se `hostapd` i `dnsmasq`, briše se `nftables` tablica `diplomski`, uklanjaju se `ufw` iznimke, vraća se `ip_forward` na 0 te se sučelje `wlan1` vraća pod nadzor `NetworkManagera`.

4.3. Konfiguracija Zeek senzora

Senzor je definiran kao servis `zeek` u obje `docker-compose` datoteke 4.10. Za razliku od ostalih servisa koji koriste izoliranu `bridge` mrežu, Zeek se izvodi u načinu mreže domaćina (*engl. host network mode*) jer mora izravno pristupiti fizičkom sučelju `wlan1` dok u izoliranoj mreži kontejner ne bi vidio promet domaćinskog sučelja. Zbog toga se njegovom kontejneru dodjeljuju ovlasti `NET_ADMIN` i `NET_RAW`, koje omogućuju otvaranje sirovih spojnih točaka (*engl. raw sockets*) i hvatanje paketa na razini sučelja.

```
zeek:
  image: zeek/zeek:8.0.6
  network_mode: "host"
  cap_add: [ NET_ADMIN, NET_RAW ]
  volumes:
    - ./zeek-logs:/usr/local/zeek/logs
    - ./zeek/local.zeek:/usr/local/zeek/share/zeek/site/local.zeek:ro
    - ./zeek/intel.dat:/usr/local/zeek/share/zeek/site/intel.dat:ro
  command: zeek -C -i wlan1 local
```

Kod 4.10. Definicija senzora u `docker-compose.yml`

Servis se pokreće naredbom `zeek -C -i wlan1 local`. Argument `-C` isključuje provjeru kontrolnih zbrojeva (*engl. checksum*) paketa (nužno jer mrežne kartice često računaju zbrojeve sklopovski, pa ih jezgra Zeeku predaje kao naizgled neispravne), `-i wlan1` određuje sučelje za nadzor, a argument `local` učitava skriptu `site/local.zeek`. Volumeni

razdvajaju pisanje od čitanja tako što je `zeek-logs` montiran je s pravom pisanja kako bi senzor u njega zapisivao, dok su `local.zeek` i `intel.dat` montirani isključivo za čitanje što je vidljivo iz dodatka :ro što znači *read-only*.

Skripta `local.zeek` učitava bazne skenere protokola, okvir za obavijesti i proširenje `json-logs` pomoću kojega se zapisi pišu u JSON formatu prikladnom za izravno strojno čitanje agenata. Uz Zeekov ugrađeni SSH (engl.*bruteforce*) detektor, u skripti su definirani i vlastite detektori. Ispis 4.11 prikazuje detekciju skeniranja portova.

```
global port_scan_tracker: table[addr, addr] of set[port] &
    create_expire=5min;

event new_connection(c: connection)
{
    local src = c$id$orig_h;
    local dest = c$id$resp_h;
    local dest_p = c$id$resp_p;

    if ([src, dest] !in port_scan_tracker)
        port_scan_tracker[src, dest] = set();
    add port_scan_tracker[src, dest][dest_p];

    if (|port_scan_tracker[src, dest]| >= 50)
        NOTICE([$note=Custom_Port_Scan, $src=src,
            $msg=fmt("Moguci port scan: %s kontaktirao %d
                razlicitih portova na %s",
                src, |port_scan_tracker[src, dest]|,
                dest),
            $identifier=cat(src, dest), $suppress_for=30sec
        ]);
}
```

Kod 4.11. Detekcija skeniranja portova u `local.zeek`

Najprije nastaje tablica za praćenje ulaza koja se indeksira s parom [izvorišna adresa, odredišna adresa] a njihova vrijednost je skup portova koji su korišteni u komunikaciji. Ukoliko je unutar pet minuta kontaktirano 50 ili više portova sa istim parom adresa, podiže se obavijest u `notice.log` i taj tip obavijesti se utišava na 30 sekundi kako upozorenja ne bi zagušavala njihov zapisnik. Portovi se brišu iz skupa nakon pet minuta kako bi se očistila memorija. Analognim se pristupom prati i učestalost SSH konekcija prema usmjerniku.

Pokazatelji kompromitacije (engl.*Indicators of Compromise*) učitavaju se iz datoteke `intel.dat` putem Zeekovog Intel okvira [18]. Adrese se navode u datoteci, a ne u skripti, čime se popis prijetnji može mijenjati bez izmjene detekcijske logike. Svi se zapisi razvrstavaju prema vrsti aktivnosti (`conn.log`, `dns.log`, `http.log`, `notice.log` i drugi) i pohranjuju u dijeljeni direktorij `zeek-logs`, kojem pristupaju podsustavi za pohranu opisani u nastavku.

4.4. Telegraf/InfluxDB i Filebeat/Elasticsearch

Podsustavi za pohranu kao ulaz koriste isti skup Zeekovih zapisa iz dijeljenog direktorija `zeek-logs`, montiranog isključivo za čitanje. Uzimaju se dva zapisa: `conn.log`, koji nosi najveći dio prometa, i `notice.log`, koji sadrži upozorenja. Time se u obje baze unosi istovjetan ulaz, što je preduvjet usporedbe iz poglavlja evaluacije. Razlike u rezultatu ovise jedino o pozadinskoj bazi i njenom agentu, a ne ulaznim podacima.

U podsustavu s InfluxDB-om unos podataka obavlja Telegraf [12]. Ulazni dodatak `inputs.tail` prati `conn.log` i `notice.log`, raščlanjuje svaki redak kao JSON (format `json_v2`) i upisuje ga u InfluxDB putem izlaza `influxdb_v2`, kojem se pristupni token, organizacija i spremnik predaju putem varijabli okoliša. Praćenje datoteka koristi metodu `poll` jer se zapisi nalaze na povezanom volumenu, gdje obavješćavanje jezgre o promjenama datoteke (`inotify`) nije pouzdano.

Pri raščlanjivanju razdvajaju se oznake (engl.*tags*) od polja (engl.*fields*). Oznake predstavljaju izvorišna i odredišna adresa, protokol, servis i stanje veze. InfluxDB ih indeksira, pa služe za filtriranje i grupiranje u Grafani. Vrijednosti visoke ili jedinstvene raznolikosti, poput portova, količine prenesenih okteta i identifikatora veze `uid`, pohranjuju se kao polja kako se ne bi nepotrebno umnažao broj vremenskih serija. Posebno specifično je raščlanjivanje Zeekovih ključeva oblika `id.orig_h` s obzirom da `json_v2` točku tumači kao razdjelnik putanje, a u zapisu je ona dio samog naziva ključa, točka se u putanji mora izuzeti 4.12

```
[[inputs.tail.json_v2.tag]]
  path      = "id\\.orig_h"    # točka je dio naziva ključa, ne
                             razdjelnik
  rename    = "src_ip"

[[inputs.tail.json_v2.field]]
  path      = "id\\.resp_p"
  rename    = "dst_port"
  type      = "int"
```

Kod 4.12. Izuzimanje točke u nazivu ključa te podjela na oznaku i polje (`telegraf.conf`)

U podsustavu s Elasticsearchom ulogu agenta preuzima Filebeat [15]. Svaki se Zeekov zapis prati zasebnim ulazom tipa `filestream` koji retke raščlanjuje kao NDJSON, a pripadnu vrstu zapisa označava poljem `zeek_type`. Procesor za vremenske oznake pretvara Zeekov `ts` (Unix vrijeme s decimalama) u standardno polje `@timestamp`. Zapisi se potom šalju u Elasticsearch i pohranjuju u indeks nazvan prema vrsti i datumu, primjerice `zeek-conn-2026.05.29` 4.13

```
filebeat.inputs:
- type: filestream
  id: zeek-conn
  paths: [ /zeek-logs/conn.log ]
```



```

    parsers:
      - ndjson: { keys_under_root: true }
      fields: { zeek_type: "conn" }

output.elasticsearch:
  hosts: [ "http://elasticsearch:9200" ]
  index: "zeek-%{[fields.zeek_type]}-%{+yyyy.MM.dd}"

```

Kod 4.13. Ulaz i odredišni indeks u filebeat.yml

Ostali tipovi zapisa (dns.log, http.log, ssl.log, dhcp.log) u konfiguraciji su pripremljeni, ali namjerno isključeni, kako bi oba podsustava unosila istovjetan skup zapisa. Upravljanje predloškom indeksa i politikom životnog ciklusa indeksa (engl. *Index Lifecycle Management, ILM*) isključeno je, pa Elasticsearch mapiranje polja stvara dinamički. Posljedice takvog mapiranja na zauzeće prostora razmatrati će se u poglavlju evaluacije.

4.5. Grafana nadzorne ploče i usluživanje

Grafana je za podsustave spremanja zajedničko vizualizacijsko sučelje [16], čime se uklanjanje utjecaj načina prikaza na usporedbu pozadinskih baza. Izvor podataka ne konfigurira se ručno, nego se učitava automatski pri pokretanju (engl. *provisioning*) iz datoteke opisa izvora, čime se izbjegava ručni unos pristupnih podataka i osigurava ponovljivost. Za podsustav s InfluxDB-om opisuje se izvor tipa influxdb s Flux jezikom upita, kojem se organizacija, spremnik i token predaju okolišnim varijablama 4.14, a za podsustav s Elasticsearchom opisuje se istovjetan izvor tipa elasticsearch nad uzorkom indeksa zeek-*. Budući da se podsustavi pokreću zasebno, svaka instanca Grafane učitava isključivo svoj izvor podataka.

```

datasources:
  - name: InfluxDB
    type: influxdb
    access: proxy
    url: http://influxdb:8086
    uid: P951FEA4DE68E13C5      # fiksni uid radi podudaranja s
      nadzornom plocom
    jsonData:
      version: Flux
      organization: ${INFLUXDB_ORG}
      defaultBucket: ${INFLUXDB_BUCKET}
    secureJsonData:
      token: ${INFLUXDB_TOKEN}

```

Kod 4.14. Automatsko učitavanje InfluxDB izvora podataka

Nadzorna ploča organizirana je u dvije skupine prikaza pregled prometa i sigurnosni pregled. Prikazi se temelje na shemi opisanoj u prethodnom odjeljku, odnosno na zapisima conn.log i notice.log te pripadnim oznakama i poljima unutar tih zapisa.

Pregled prometa čine prikaz broja veza po minuti (koji broji zapise veza u kliznim jed-

nominutnim prozorima), raspodjela protokola (kružni prikaz dobiven grupiranjem po oznaci proto) te ljestvice najčešćih izvorišnih i odredišnih adresa. Primjer Flux upita, za prikaz broja veza po minuti, dan je u ispisu 4.15; oznake se prije zbrajanja uklanjaju kako bi se pojedinačne vremenske serije sažele u jednu vrijednost.

```
from(bucket: "zeek-logs")
  |> range(start: v.timeRangeStart, stop: v.timeRangeStop)
  |> filter(fn: (r) => r._measurement == "zeek_conn")
  |> filter(fn: (r) => r._field == "uid")
  |> drop(columns: ["src_ip", "dst_ip", "proto", "service", "conn_state"])
  |> aggregateWindow(every: 1m, fn: count, createEmpty: false)
  |> yield(name: "connections_per_minute")
```

Kod 4.15. Flux upit prikaza broja veza po minuti

Posebno je vrijedan prikaz najčešćih izvorišnih adresa. Budući da Zeek promet hvata na sučelju wlan1 prije prevođenja adresa, izvorišne adrese ostaju stvarne adrese uređaja u lokalnoj mreži (primjerice 10.0.1.94), pa ih je u prikazu moguće i imenovati. Time prikaz izravno potvrđuje vrijednost odluke o mjestu nadzora iz poglavlja arhitekture. Kada bi se hvatanje provodilo nakon prevođenja adresa, svi bi se izvorišni uređaji stopili u jednu adresu usmjernika i atribucija po uređaju bila bi izgubljena.

Sigurnosni pregled čine tablica upozorenja (najnovija upozorenja iz zeek_notice s tipom i izvorišnom adresom), vremenski prikaz učestalosti upozorenja te tablica sumnjivih veza. Potonja izdvaja veze čije stanje (conn_state) odstupa od urednog dovršetka (SF) i grupira ih po stanju i izvorišnoj adresi, čime se ističu obrasci poput velikog broja neuspjelih ili odbijenih veza s jednog izvora.

Istovjetna nadzorna ploča izrađena je i za podsustav s Elasticsearchom, s istim prikazima, ali s upitima prilagođenima Elasticsearch jeziku upita. Budući da se prikazi i njihov raspored podudaraju, usporedba dvaju podsustava ne ovisi o načinu vizualizacije.

4.6. Automatska reakcija: auto_reaction.py i nftables

Za razliku od ostalih komponenata, skripta za automatsku reakciju auto_reaction.py izvodi se izravno na domaćinu, a ne u kontejneru, jer mijenja vatrozidna pravila domaćina i za to zahtijeva administratorske ovlasti. Skripta povezuje detekciju, odnosno Zeekova upozorenja [18], s odgovorom, tj. blokiranjem putem nftables kroz denylist.

Skripta prati najnovije retke datoteke notice.log naredbom tail -F -n 0 gdje zastavica -n 0 osigurava da se pri pokretanju zanemare postojeći zapisi, pa se reagira isključivo na nova upozorenja, a ne na povijest zapisanu prije pokretanja.

Za svako novo upozorenje skripta čita njegov tip (note) i izvorišnu adresu. Izvorišna

se adresa preuzima iz polja `src`, a ako ono ne postoji, iz polja `id.orig_h` 4.16 Razlog je tomu što vlastiti detektori postavljaju `$src` bez pridružene veze, dok upozorenja vezana uz konkretnu vezu nose `id.orig_h`.

```
note    = entry.get("note", "")
src_ip  = entry.get("src") or entry.get("id.orig_h", "")

if note in TARGET_NOTICES and src_ip and src_ip not in WHITELIST:
    :
    if src_ip not in BLOCKED_IPS:
        block(src_ip)    # nft add element ip diplomatski denylist
                           { src_ip }
```

Kod 4.16. Srž odlučivanja u `auto_reaction.py`

Odgovor se pokreće isključivo za unaprijed određen skup upozorenja (`TARGET_NOTICES`) kao pokušaji skeniranja portova, pogađanje SSH lozinke te podudaranja s pokazateljima kompromitacije. Na taj način operator može smanjiti (ili povećati) broj upozorenja ovisno o situaciji i potrebama. Adresa usmjernika i adresa domaćina se nalaze u listi dozvoljenih (`WHITELIST = "127.0.0.1", "10.0.1.1"`) kako se ne bi mogla blokirati vlastita infrastruktura.

Blokada se provodi dodavanjem izvorišne adrese u skup `denylist` unutar tablice `diplomski`. Sam skup i lanci koji odbacuju promet definirani su ranije, pri postavljanju mreže 4.6 Skripta mijenja isključivo članstvo skupa, ne lance ni pravila. Zbog toga bilo kakav nenadani pad skripte ne ostavlja vatrozidna pravila ne nadzirana već se jezgra brine o tome da se pobrišu nakon zadanog vremena.

Trajanje blokiranja ne određuje skripta, nego se očitava iz trenutne (*engl.live*) konfiguracije samog skupa (funkcija `read_timeout`) kao jedinstvenog izvora istine. Istek pojedinog elementa potom obavlja jezgra operacijskog sustava na temelju vremenskog ograničenja skupa, neovisno o skripti. Posljedica je otpornost na nasilni prekid. Prekine li se skripta signalom `SIGKILL`, ponestankom memorije ili gubitkom napajanja, elementi svejedno isteknu sami, a cjelokupno se stanje uklanja brisanjem tablice. Skripta uz to vodi vlastitu evidenciju blokiranih adresa isključivo radi izbjegavanja ponovnog dodavanja iste adrese, dok zasebna dretva uklanja istekle zapise iz te evidencije. Blokada se bilježi tek ako je naredba `nft` uspješno izvršena, čime se izbjegava halucinirana evidencija nepostojeće blokade.

4.7. Izazovi pri implementaciji

Izgradnja sustava nije tekla bez zastoja. U nastavku se opisuju najznačajniji problemi uočeni tijekom implementacije i način na koji su riješeni, redom kako su se javljali kroz slojeve sustava.

Već pri postavljanju kontejnerâ utvrđeno je da ranije korištena slika `zeekur/zeek` više nije dostupna, pa je zamijenjena službenom slikom `zeek/zeek:8.0.6`.

Na mrežnom sloju prvi je izazov bio sukob oko upravljanja sučeljem. `NetworkManager` preuzimao je sučelje `wlan1` i gasio pristupnu točku koju podiže `hostapd`. Problem je riješen izuzimanjem sučelja iz njegova nadzora naredbom `nmcli device set wlan1 managed no` prije konfiguracije pristupne točke [20].

Nakon što su `hostapd` i `dnsmasq` bili aktivni, a `wlan1` ispravno konfiguriran, klijenti i dalje nisu dobivali adresu. Pregledom `nft list ruleset` utvrđeno je da `ufw` presreće DHCP pakete (ulaz 67/UDP) i odbacuje ih prije nego dopiju do `dnsmasq`-a. Problem je otklonjen izrijekom dopuštenim DHCP prometom i usmjeravanjem na sučelju `wlan1`, pravilima koja su potom ugrađena u skriptu `net_setReset_rules.sh` radi ponovljivosti.

Pokretanje `dnsmasq`-a isprva nije uspijevalo zbog zauzetosti ulaza 53 (`Address already in use`), koji je na povratnim adresama držao sistemski razlučivač `systemd-resolved`. Budući da `dnsmasq` ionako treba slušati samo na `wlan1`, sukob je otklonjen direktivom `bind-interfaces` kojom `dnsmasq` sluša isključivo na navedenom sučelju umjesto na svim adresama, bez gašenja sistemskog razlučivača. Uz to, prva inačica naziva mreže sadržavala je zagrade i razmake, koje `hostapd` odbija kao nevaljane znakove u SSID-u, pa je naziv prilagođen.

Na sloju ingestije zapisi pri prvom pokretanju Telegrafa nisu dospijevali u `InfluxDB`. Uzrok je bilo pogrešno raščlanjivanje Zeekovih ključeva. Format `json_v2` točku tumači kao razdjelnik putanje, dok je u nazivima poput `id.orig_h` ona dio samog ključa. Tek nakon izuzimanja točke u konfiguraciji (`id\.``orig_h`) podatci su ispravno raščlanjeni i upisani. Dodatno, datoteka `conn.log` ne nastaje pri pokretanju Zeeka nego tek pri prvoj zabilježenoj vezi, pa je Telegraf u međuvremenu prijavljivao njezino nepostojanje; problem se rješava sam čim kroz mrežu prođe promet.

U pogledu detekcije isprva je za skeniranje portova učitana ugrađena politika `policy/misc/scan`. U korištenoj je inačici Zeeka ta politika zastarjela i prestala je raditi, a prikladna zamjena uključena u Zeek instalaciju nije pronađena. Stoga je detekcija skeniranja preseljena u vlastiti detektor opisan ranije, čime je uklonjena ovisnost o zastarjeloj i nepodržanoj politici.

Na sloju vizualizacije uočeno je da nadzorne ploče na čistom postavljanju ne pronalaze svoj izvor podataka. Uzrok je u tome što Grafana izvoru bez izrijekom zadanog identifikatora dodjeljuje nasumičan `uid` [16], koji se onda ne podudara s identifikatorom zapisanim u izvezenoj nadzornoj ploči. Problem je riješen ručnim postavljanjem polja `uid` u opisu izvora podataka unutar `grafana/provisioning/datasources/influxdb.yaml` (i sličnoj putanji za Elasticsearch), čime se podudaranje osigurava pri svakom postavljanju.

Razlika između dvaju pozadinskih sustava očitovala se i pri vremenskim prikazima. Elasticsearch ograničava broj segmenata histograma (`search.max_buckets`, zadano 65536); fiksni interval poput jedne minute nad širokim vremenskim rasponom premašuje tu granicu, što se kod InfluxDB-a ne događa. Prikazi su prilagođeni korištenjem automatskog intervala koji se podešava prema odabranom rasponu. Ovo je ujedno konkretan primjer razlike u modelu dvaju sustava, detaljnije razmotrene u poglavlju evaluacije.

Naposljetku, pri opterećenju prometom generiranim alatom `t50` uočeno je da Zeek počinje gubiti pakete, što bilježi u zapisu `capture_loss.log`, kada dotok premaši približno pedeset tisuća paketa u sekundi. Za promet tipičan na lokalnoj mreži ciljanih razmjera to ne predstavlja ograničenje, no zabilježeno je kao gornja granica pouzdanog hvatanja na korištenom sklopovlju.

5. Evaluacija podsustava za pohranu

Cilj ovog poglavlja jest usporediti dva ispitana podsustava za pohranu opisana u poglavljima arhitekture i implementacije. Vremenski orijentiranu bazu InfluxDB s agentom Telegraf te dokumentno orijentiranu bazu Elasticsearch s agentom Filebeat. Usporedba se provodi nad istovjetnim ulaznim podacima kako bi se uočene razlike mogle pripisati isključivo pozadinskoj bazi i njezinu agentu, a ne ulazu. Naglasak je na trima mjerljivim svojstvima koja su za ciljanu primjenu (potrošački laptop ograničenih resursa) presudna - zauzeću prostora na disku, potrošnji radne memorije te kašnjenju upita.

5.1. Metodologija usporedbe

Mjerenja su provedena na domaćinu temeljenom na jezgri 7.0.1 carchos (x86_64) s ukupno približno 12 GB dostupne radne memorije. Korištene su inačice InfluxDB 2.7, Elasticsearch 8.17 i Grafana 11.4, dok je veličina JVM gomile Elasticsearcha ograničena postavkom `ES_JAVA_OPTS=-Xms512m` odnosno 512 MB.

Za razliku od produkcijske konfiguracije, u kojoj se zbog sukoba na ulazu 3000 (Grafana) i istovjetnog naziva senzorskog kontejnera izvodi isključivo jedan podsustav, mjerenja su provedena uz istovremeno podignute obje baze i pripadne agente, no bez Grafane i bez senzora. Time se obje baze izlažu istom opterećenju domaćina u istom trenutku, pa su mjerenja međusobno usporediva pod identičnim uvjetima. Kao ulaz korišten je jedan zamrznuti zapis `conn.log` veličine 4.7 MB s 14027 zapisa veza, koji oba agenta čitaju iz istoga dijeljenog direktorija.

Poštenost usporedbe počiva na tome da oba podsustava obrade isti ulaz, svaki ga pročitavši točno jednom, a to se provjerava brojem zapisa. Elasticsearch indeksira svaki redak kao zaseban dokument, pa broj dokumenata mora odgovarati broju redaka ulaza. InfluxDB, naprotiv, točku jednoznačno određuje kombinacijom mjerenja, skupa oznaka i vremenske oznake. Zapisi s istovjetnim vrijednostima tih polja stapaju se u jednu točku umjesto da se pišu zasebno. Posljedica je da InfluxDB prijavljuje nešto manji broj točaka od broja ulaznih redaka, što nije gubitak podataka nego svojstvo modela pohrane i detaljnije se razmatra u

raspravi. Izmjereni su brojevi prikazani u tablici 5.1.

Izvor	Broj zapisa
Redaka u conn.log (ulaz)	14027
Elasticsearch dokumenata	14027
InfluxDB točaka (zeek_conn)	13435

Tablica 5.1. Provjera istovjetnosti ulaza

Mjerenja su automatizirana skriptom `benchmark.sh`, koja redom provodi provjeru ulaza, mjerenje prostora, uzorkovanje memorije i mjerenog kašnjenja upita.

5.2. Potrošnja prostora na disku

Mjeri se zauzeće na disku za istovjetan skup Zeekovih zapisa, uz izvornu datoteku `conn.log` kao referentnu vrijednost. Za InfluxDB mjeri se veličina podatkovnog direktorija pripadnog spremnika (engl.*bucket*), a za Elasticsearch veličina indeksa `zeek-conn` dobivena iz sučelja `_cat/indices`.

Izvor	Zauzeće
Sirovi conn.log referenca	4.7 MB
Elasticsearch indeks zeek-conn	4.8 MB
InfluxDB spremnik zeek-logs	1.5 MB

Tablica 5.2. Zauzeće prostora na disku

Kao dodatni kontekst pri tumačenju ovih vrijednosti potrebno je naglasiti veličinu izmjerenog skupa. Drugim riječima izmjereni skup je malen (reda veličine nekoliko megabajta), pa razlike u zauzeću prostora prouzročavaju ponajprije dodatni troškovi formata pohrane, a ne ponašanje pri rastu količine podataka. Elasticsearch gradi invertirani indeks (uz pohranu podataka) koji radi pretrage po sadržaju polja, što povećava zauzeće diska u odnosu na sam volumen ulaza. InfluxDB, naprotiv, primjenjuje kompresiju prilagođenu vremenskim nizovima, pa je izmjereni spremnik (1.5 MB) zauzeo otprilike trećinu Elasticsearchova indeksa i manje od same sirove datoteke. Posljedice tih značajki baza detaljnije se razmatraju u raspravi.

5.3. Potrošnja radne memorije

Potrošnja radne memorije mjerena je po kontejneru, u tri uzorka nakon što se sustav prilagodio, korištenjem Docker statistike. Tablica 5.3. prikazuje reprezentativne vrijednosti.

Razlika u potrošnji memorije najizraženija je i najpostojanija od svih mjerenih veličina. Cijeli podsustav s InfluxDB-om (baza i agent) zadržava se na razini oko 146 MB, dok podsustav s Elasticsearchom (baza i agent) troši oko 660 MB, odnosno približno četiri i pol puta

Kontejner	Radna memorija
InfluxDB (baza, podsustav A)	106 MB
Telegraf (agent, podsustav A)	40 MB
Elasticsearch (baza, podsustav B)	576 MB
Filebeat (agent, podsustav B)	84 MB

Tablica 5.3. Potrošnja radne memorije po kontejneru (nakon prilagodbe)

više. Bitno je da ta razlika nije posljedica količine podataka, nego donje granice koju nameće Java virtualni stroj. Potrošnja Elasticsearcha određena je prije svega zadanom veličinom JVM gomile (ovdje 512 MB), koja predstavlja donju granicu neovisnu o broju pohranjenih zapisa. Uz veću gomilu otisak bi bio i veći. Za ciljanu primjenu na sklopovlju ograničenih resursa ta je donja granica presudna i razmatra se u zaključku. Također je bitno za napomenuti da je ta granica pomična no naravno što se više memorije udijeli to su pretraživanja brža.

5.4. Kašnjenje upita

Mjereno je kašnjenje triju upita koje koristi i nadzorna ploča: brojanje veza, ljestvica deset najčešćih odredišnih adresa te agregacija broja veza po vremenskim prozorima. Svaki je upit pokrenut deset puta, uz odbacivanje dvaju početnih pokretanja radi zagrijavanja, a prijavljeni su medijan te najmanja i najveća izmjerena vrijednost. Mjeri se ukupno kašnjenje kakvo klijent vidi na povratnoj adresi, dakle uključujući obradu zahtjeva, a ne samo unutarnje vrijeme izvođenja upita u jezgri baze. Kako bi usporedba bila poštena, brojanje u oba sustava obavlja prolaz kroz zapise (u Elasticsearchu agregacijom `value_count`, a ne očitanjem održavanoga broja dokumenata).

Upit	InfluxDB (Flux)	Elasticsearch
Brojanje (sken)	49,5 (45,3-51,9)	4,4 (4,0-5,3)
Deset najčešćih odredišta	42,4 (40,3-44,5)	5,1 (4,4-5,3)
Agregacija po minutama	63,6 (62,8-64,9)	7,4 (6,1-9,1)

Tablica 5.4. Kašnjenje upita: medijan (najmanje-najveće), u milisekundama

Na svim trima upitima Elasticsearch postiže niže kašnjenje. Rezultat je nužno tumačiti uz činjenicu da je izmjereni skup malen, pa se mjeri pretežno dodatni trošak izvođenja upita (priprema Flux upita i obrada zahtjeva nad sučeljem InfluxDB-a naspram Luceneova izvođenja u Elasticsearchu), a ne ponašanje pri rastu količine podataka. Apsolutne su vrijednosti u oba sustava niske i za potrebe osvježavanja nadzorne ploče u sekundnim razmacima posve dostatne; razlika bi mogla dobiti na značaju tek pri znatno većim skupovima ili pri upotrebi za pravovremenu reakciju, što ostaje smjernicom za daljnji rad.

5.5. Rasprava rezultata

Mjerenja se mogu objediniti kroz razliku u modelu podataka dvaju sustava, opisanu u poglavlju o teorijskim osnovama. Elasticsearch svaki Zeekov zapis tretira kao dokument i nad poljima gradi invertirani indeks, što mu daje snažnu pretragu punim tekstom, povoljno kašnjenje agregacijskih upita i korelaciju izvora, ali po cijeni većega prostornog otiska i, presudno, donje granice radne memorije koju nameće JVM. InfluxDB je optimiziran za vremenske nizove pa mu je vrijeme glavna organizacijska dimenzija. Također primjenjuje kompresiju i politike zadržavanja, a memorijski otisak ostaje malen. Iz istoga modela slijedi i opažena razlika u broju zapisa iz tablice 5.1. Budući da InfluxDB točku određuje skupom oznaka i vremenskom oznakom, veze koje dijele te vrijednosti stapaju se u jednu točku, pa je broj točaka manji od broja ulaznih redaka. Stapanje pogađa isključivo agregatni broj zapisa veza (otprilike 4%) i posljedica je svjesne odluke da se identifikator veze `uid` drži poljem, a ne oznakom - držanje oznakom očuvalo bi svaki redak, ali bi količina vremenskih serija naraslo na broj veza i poništilo memorijsku prednost zbog koje se InfluxDB i odabire. Zapisi `notice` nisu zahvaćeni. Za primjenu usmjerenu na vizualizaciju obrazaca i dojavu, a ne na forenzičku rekonstrukciju pojedine veze, riječ je o prihvatljivom kompromisu. Unutar Elasticsearcha, gdje je svaki redak zaseban dokument, takvoga stapanja nema.

Posljedica je očita specijalizacija alata. InfluxDB je bolji izbor kada su upiti temeljeni na vremenu i kad su računalni resursi domaćina oskudni. Kad su potrebni pretraga po sadržaju polja (primjerice traženje domena u `dns.log`), niže kašnjenje složenijih agregacija i korelacija više vrsta zapisa u jednom upitu Elasticsearch se ističe kao očiti odabit. InfluxDB ne podržava prirodno te mogućnosti te zahtijeva agregaciju na strani klijenta.

Naposljetku valja istaknuti glavno ograničenje cijele evaluacije. Mjerenja su provedena na malenom skupu podataka, pa pouzdano govore o fiksnim zapisima i donjim granicama potrošnje, ali ne i o ponašanju sustava pri znatnom rastu količine prometa. Mjerenje na većem skupu ostavlja se kao smjernica za daljnji rad iako se može primjetiti trend gdje bi Elasticsearch bio puno bolja opcija.

5.6. Zaključak usporedbe

Za ciljanu primjenu ovog rada, nadzor lokalne mreže na potrošačkom sklopovlju ograničenih resursa, odlučujućom se pokazuje potrošnja radne memorije. Podsustav s InfluxDB-om zadržava se na razini stotinjak megabajta, dok podsustav s Elasticsearchom troši višestruko više, ponajprije zbog donje granice koju nameće JVM gomila. Ta je granica neovisna o količini pohranjenih podataka, pa Elasticsearch i pri zanemarivu opterećenju zauzima više memorije nego cijeli InfluxDB podsustav pod radnim opterećenjem; na domaćinu koji istovremeno obavlja uloge usmjernika, pristupne točke i senzora upravo je taj fiksni prag presu-

dan. Tu je granicu moguće spustiti preko argumenata no onda Elasticsearch gubi prednost koju trenutno ima.

Na svim trima izmjerenim upitima Elasticsearch postiže niže kašnjenje 5.4. Apsolutne su vrijednosti obaju sustava ipak reda nekoliko desetaka milisekundi i za osvježavanje nadzorne ploče u sekundnim razmacima zanemarive, pa ne mijenjaju odluku koju daje memorijski otisak. Zauzeće diska na izmjerenom je skupu premaleno da bi samo po sebi bilo argumentom te se u ovom zaključku ne uzima kao odlučujuće.

Stoga se za produkcijsku konfiguraciju, u skladu s najavom iz poglavlja arhitekture da se odabire jedan od dvaju podsustava, bira InfluxDB. Time se ujedno pokazuje da je usporidivu temeljnu funkcionalnost moguće postići uz memorijski otisak reda veličine stotinjak megabajta, znatno ispod zahtjeva sveobuhvatnih rješenja poput Security Oniona navedenih u poglavlju o teorijskim osnovama.

Elasticsearch ostaje prikladan kad su potrebni pretraga po sadržaju polja (primjerice traženje domena u `dns.log`), niže kašnjenje složenijih agregacija i korelacija više vrsta zapisa u jednom upitu. Te prednosti slijede iz modela podataka, no nisu zasebno izmjerene u ovom radu jer mjerenja obuhvaćaju samo `conn.log` te se njihova kvantifikacija ostavlja kao smjernica za daljnji rad.

6. Testiranje detekcije i automatske reakcije

Cilj je ovog poglavlja funkcionalno provjeriti dvije sposobnosti sustava koje nisu obuhvaćene usporedbom podsustava za pohranu iz prethodnog poglavlja. Sposobnost prepoznavanja sumnjivog ponašanja u prometu te sposobnost automatskog odgovora na prepoznatu prijetnju. Provjera se provodi kao niz nadziranih testova u kojima se s poznatog klijenta izaziva određeni obrazac prometa, a potom se promatra cijeli lanac od Zeekova upozorenja u `notice.log`, preko skripte `auto_reaction.py`, do izmjene članstva skupa `denylist` u tablici `nftables`. Svaki se test prati po izvorišnoj adresi, čime se uspostavlja jednoznačna veza između izazvanog događaja, zabilježenog upozorenja i poduzete reakcije. Navode se isključivo stvarno izmjereni zapisi.

6.1. Testno okruženje i metodologija

Testovi su provedeni na sklopovlju opisanom u poglavlju arhitekture. Prijenosno računalo istovremeno obavlja uloge usmjernika i bežične pristupne točke, pri čemu je sučelje `enp2s0` povezano prema vanjskoj mreži (`eduroam`), a sučelje `wlan1` podiže pristupnu točku za lokalnu podmrežu `10.0.1.0/24`. Postavljene su dvije jasno razdvojene uloge:

- **Napadač** — klijent priključen na pristupnu točku. U svim je testovima detekcije korišten mobilni uređaj s adresom `10.0.1.94`.
- **Branitelj i senzor** — samo prijenosno računalo (`10.0.1.1`), na kojem rade Zeek, `nftables` i skripta `auto_reaction.py`.

Zeek promet hvata na sučelju `wlan1`, dakle prije prevođenja mrežnih adresa, pa izvorišne adrese ostaju stvarne adrese uređaja u lokalnoj mreži - ta je činjenica ključna jer omogućuje pripisivanje upozorenja pojedinom uređaju.


Za izazivanje pojedinih obrazaca prometa korišteni su sljedeći alati: `nmap` za skeniranje portova, `sshpass` za automatske ponavljane pokušaje prijave putem SSH, `curl` za uspostavljanje veze alatom prema adresi iz datoteke `intel.dat` za podudaranje s pokazateljem kompromitacije te `hping3` za lažiranje izvorišne adrese pri ispitivanju ograničenja.

Reakcija se temelji na sljedećem ponašanju skripte: po prepoznavanju obavijesti izvorišna adresa (src) dodaje se kao element skupa denylist s vremenskim ograničenjem od 30 sekundi, osim ako se nalazi na popisu dopuštenih adresa. U redovnom radu popis dopuštenih adresa sadrži 127.0.0.1 i 10.0.1.1; adresa 10.0.1.94 dodana je na taj popis isključivo za potrebe testiranja.

Radi provjere lažno pozitivnih odziva kroz pristupnu je točku propušten uobičajen promet (pregledavanje weba, dohvaćanje datoteka, ažuriranja sustava) tijekom *3 sata 38 minuta 41 sekunde*. Nijedan obrazac nije premašio pragove definirane u `local.zee` (50 različitih portova u pet minuta odnosno 15 SSH veza), pa skup denylist nije popunjen niti je jedan legitiman uređaj blokiran.

6.2. Provjera toka podataka


Prije ispitivanja detekcije potvrđuje se da podatci prolaze cijelim lancem obrade. Na klijentu se uspostavi veza, nakon čega se utvrđuje da je nastao zapis u `conn.log`, da ga je preuzeo agent (Telegraf odnosno Filebeat), da je pohranjen u pripadnoj bazi te da je vidljiv na odgovarajućem prikazu u Grafani. Na nadzornoj ploči 6.1. izravno se očitava da podatci pristižu - prikazani su broj veza u minuti, raspodjela protokola te ljestvice najčešćih izvorišnih i odredišnih adresa, u kojima se pojavljuju stvarne adrese klijenata iz lokalne pod mreže. Time je potvrđeno da je tok podataka cjelovit i da se izvorišne adrese očuvane na sučelju wlan1 ispravno prenose do prikaza.



Slika 6.1. Prikaz podataka na nadzornoj ploči: broj veza u minuti, raspodjela protokola te najčešći izvori i odredišta; u promatranom razdoblju nema upozorenja (osnovno stanje prometa)

6.3. Testiranje detekcije

Provedena su tri testa detekcije: skeniranje portova, bruteforce SSH prijave i podudaranja s pokazateljem kompromitacije. Svi su izvedeni s klijenta 10.0.1.94, osim lažiranog skeniranja iz odjeljka o ograničenjima. Sva tri tipa upozorenja vidljiva su na vremenskoj crti nadzorne ploče 6.2., s pripadnim izvorišnim adresama.



Slika 6.2. Vremenska crta upozorenja: Custom_Port_Scan (185.220.101.1) te Custom_SSH_Bruteforce i Intel::Notice (oba 10.0.1.94)

6.3.1. Skeniranje portova

Skeniranje je izazvano s klijenta 10.0.1.94 naredbom `nmap -Pn -T4 10.0.1.1`. Prekoračenjem praga od 50 različitih kontaktiranih portova prema istom cilju, Zeek je zabilježio upozorenje tipa Custom_Port_Scan sa stvarnom izvorišnom adresom 10.0.1.94. Detektor djeluje na događaju `new_connection`, pa reagira na pokušaj veze i ne ovisi o njezinom uspješnom uspostavljanju.

```
{ "ts": 1781467564.943518, "note": "Custom_Port_Scan",  
  "msg": "Moguci port scan: 10.0.1.94 kontaktirao 50 razlicitih  
         portova na 10.0.1.1",  
  "src": "10.0.1.94", "actions": ["Notice::ACTION_LOG"],  
  "email_dest": [], "suppress_for": 30.0 }
```

Kod 6.1. Upozorenje o skeniranju portova (notice.log)

6.3.2. Bruteforce SSH prijave

Bruteforce je izveden s klijenta 10.0.1.94 kao 40 uzastopnih neuspjelih pokušaja prijave putem SSH (alat `sshpass`) prema domaćinu. Korišteni prilagođeni detektor broji *učestalo*st veza prema portu 22, neovisno o ishodu autentikacije, te je komplementaran Zeekovu detektoru `SSH::Password_Guessing` koji radi na temelju zaključene autentikacije. Pri pragu od 15 veza zabilježeno je upozorenje tipa Custom_SSH_Bruteforce; tijekom 40 pokušaja istek prozora suzbijanja (30 s) doveo je do druge obavijesti pri 36 veza.

```
{ "ts": 1781468972.322033, "note": "Custom_SSH_Bruteforce",
```

```
"msg":"Moguci SSH bruteforce: 10.0.1.94 otvorio 15 konekcija
prema portu 22 na 10.0.1.1",
"src":"10.0.1.94","suppress_for":30.0}
{"ts":1781469003.721936,"note":"Custom_SSH_Bruteforce",
"msg":"Moguci SSH bruteforce: 10.0.1.94 otvorio 36 konekcija
prema portu 22 na 10.0.1.1",
"src":"10.0.1.94","suppress_for":30.0}
```

Kod 6.2. Dvije obavijesti o SSH bruteforceu tijekom istog niza pokušaja (*notice.log*)

Obavijesti su vidljive i na nadzornoj ploči 6.3., gdje je za izvor 10.0.1.94 zabilježeno više detekcija Custom_SSH_Bruteforce pri pragovima od 15 te 35–36 veza.

Upozorenja ⓘ			
_time	Upozorenje	Tip	Izvor
2026-06-14 22:39:35	Moguci SSH bruteforce: 10.0.1.94 otvorio 35 konekcija prema portu 22 na	Custom_SSH_Brutefo	10.0.1.94
2026-06-14 22:38:54	Moguci SSH bruteforce: 10.0.1.94 otvorio 15 konekcija prema portu 22 na	Custom_SSH_Brutefo	10.0.1.94
2026-06-14 22:30:03	Moguci SSH bruteforce: 10.0.1.94 otvorio 36 konekcija prema portu 22 na	Custom_SSH_Brutefo	10.0.1.94
2026-06-14 22:29:32	Moguci SSH bruteforce: 10.0.1.94 otvorio 15 konekcija prema portu 22 na	Custom_SSH_Brutefo	10.0.1.94

Slika 6.3. Upozorenja o SSH bruteforceu na nadzornoj ploči (izvor 10.0.1.94)

6.3.3. Podudaranje s pokazateljem kompromitacije

Podudaranje je izazvano uspostavljanjem veze s klijenta 10.0.1.94 prema adresi unaprijed unesenoj u datoteku *intel.dat*. Putem okvira (engl.*Intel framework*) (skripte *intel/seen* i *intel/do_notice*) Zeek poklapa adrese na događaju uspostavljene veze (*connection_established*); za test je stoga ključno da se veza *uspostavi*, neovisno o ishodu na aplikacijskoj razini. Veza je rezultirala neuspjehom pri (engl.*TLS*) pregovaranju, ali je TCP rukovanje dovršeno, što je dovoljno za poklapanje. Zeek je zabilježio upozorenje tipa *Intel::Notice 6.3*

```
{"ts":1781471801.228362,"id.orig_h":"10.0.1.94","id.resp_h":
"172.66.147.243",
"id.resp_p":443,"proto":"tcp","note":"Intel::Notice",
"msg":"Intel hit on 172.66.147.243 at Conn::IN_RESP",
"src":"10.0.1.94","dst":"172.66.147.243","p":443,"
suppress_for":3600.0}
```

Kod 6.3. Upozorenje o podudaranju s pokazateljem kompromitacije (*notice.log*)

Za testni je indikator korištena dostupna javna adresa, što je uobičajena i sigurna praksa pri provjeri Intel okvira. Vrijednost *suppress_for* ovdje iznosi 3600 sekundi (zadani interval suzbijanja obavijesti); taj se interval prema potrebi snižava postavkom u *local.zeek*, čime se trguje između količine obavijesti i odzivnosti te je on odvojen od *TIMEOUT* kojeg se postavlja za duljinu trajanja blokade unutar nft tablice *denylist*.

6.4. Testiranje automatske reakcije

6.4.1. Blokiranje izvora i istek blokade

Reakcija je promatrana na primjeru skeniranja portova iz ispisa 6.1 Prije testa skup denylist bio je prazan; ubrzo nakon detekcije izvorišna se adresa nalazi u skupu, uz preostalo vrijeme do isteka koje očitava jezgra 6.4 Skripta `auto_reaction.py` pritom je ispisala odgovarajuću potvrdu 6.5

```
# prije:
table ip diplomski {
    set denylist { type ipv4_addr ; timeout 30s }
}
# tijekom blokade:
table ip diplomski {
    set denylist {
        type ipv4_addr
        timeout 30s
        elements = { 10.0.1.94 expires 22s818ms }
    }
}
```

Kod 6.4. Skup denylist prije i tijekom blokade

```
[!] Detektiran Custom_Port_Scan.
[!] Blokirani IP: 10.0.1.94
[+] Istekla evidencija blokade: 10.0.1.94
```

Kod 6.5. Ispis skripte `auto_reaction.py`

Trajanje blokade određeno je vremenskim ograničenjem skupa (`timeout 30s`). Nakon isteka blokade jezgra automatski uklanja element, bez intervencije skripte ili operatora. To je moguće potvrditi porukom o isteku u svakom testu te ponovnim pregledom praznog skupa.

Za odlaznu vezu prema pokazatelju kompromitacije skripta blokira polje `src` iz obavijesti, a to je *unutarnji* klijent koji je ostvario vezu (10.0.1.94), a ne vanjska maliciozna adresa. Riječ je o namjernom postupku. Vanjska je adresa izvan dosega upravljanja, dok se blokiranjem unutarnjeg domaćina ograničava daljnja komunikacija potencijalno kompromitiranog uređaja.

Blokada je potvrđena i pregledom skupa nakon podudaranja s pokazateljem kompromitacije. U skupu denylist nalazi se unutarnji klijent 10.0.1.94, a ne vanjska adresa indikatora 6.6

```
table ip diplomski {
    set denylist {
        type ipv4_addr
        timeout 30s
        elements = { 10.0.1.94 expires 11s813ms }
    }
}
```

```
}
```

Kod 6.6. Skup denylist nakon podudaranja s pokazateljem kompromitacije

6.4.2. Zaštita vlastite infrastrukture popisom dopuštenih adresa

Provjereno je da skripta ne reagira kad je izvorišna adresa na popisu dopuštenih. U testu je adresa 10.0.1.94 privremeno dodana na popis, nakon čega je ponovljen SSH bruteforce. Zeek je i dalje zabilježio upozorenje Custom_SSH_BruteForce (detekcija nije izostala), no skup denylist ostao je prazan, a skripta nije poduzela reakciju 6.7 Time je potvrđeno da popis dopuštenih adresa sprječava blokiranje povjerljivih izvora bez utjecaja na detekciju.

```
# WHITELIST = {"127.0.0.1", "10.0.1.1", "10.0.1.94"}
[*] Nadzor pokrenut nad zeek-logs/notice.log
# upozorenje se nalazi u notice.log, ali skripta nije
    reagirala
# skup denylist ostao prazan
# sustav radi kako bi i trebao
```

Kod 6.7. Detekcija bez reakcije za adresu na popisu dopuštenih

6.5. Ograničenja uočena testiranjem

6.5.1. Lažiranje izvorišne adrese

Reakcija se temelji na izvorišnoj adresi iz obavijesti, pa je njezina ispravnost ograničena ispravnošću te adrese. Ograničenje je provjereno namjernim lažiranjem izvorišne adrese alatom hping3, kojim je izvedeno skeniranje portova uz krivotvorenu adresu 185.220.101.1 (hping3 -S --spooof 185.220.101.1 --scan 1-1000 10.0.1.94). Zeek je zabilježio upozorenje s krivotvorenom adresom, a skripta je upravo nju dodala u skup denylist 6.8

```
# notice.log: "note":"Custom_Port_Scan", "src
    ":"185.220.101.1"
table ip diplomski {
    set denylist {
        type ipv4_addr
        timeout 30s
        elements = { 185.220.101.1 expires 19s395ms
    }
}
```

Kod 6.8. Ispis denylist

Potvrđeno je očekivano, ali nepoželjno ponašanje. Sustav blokira adresu navedenu u obavijesti, koja ne mora odgovarati stvarnom napadaču. Stvarni napadač ostaje neblokirani, a lažira li adresu legitimnog uređaja koji nije na popisu dopuštenih, sustav će blokirati taj uređaj. Popis dopuštenih adresa tu ne pomaže jer štiti samo usmjernik i lokalnog domaćina,

a ne i proizvoljne uređaje od povjerenja; štoviše, oslanja se na izvorišnu adresu koja je i sama krivotvorljiva. Djelotvorno ublažavanje je filtriranje na ulazu sučelja wlan1 (odbacivanje paketa čija izvorišna adresa nije iz 10.0.1.0/24), čime se krivotvoreni paket odbacuje prije detekcije.

Valja razlučiti i opseg sposobnosti. Detekcija i reakcija djeluju nad prometom koji Zeek vidi na sučelju wlan1; nepozvani dolazni promet iz širega područja mreže na sučelju enp2s0 odbacuje se zadanom politikom vatrozida ufw i nije zadaća ovoga sloja.

6.5.2. Otpornost na nasilni prekid skripte

Budući da trajanje blokade nameće vremensko ograničenje skupa, a ne sama skripta, nasilni prekid skripte ne ostavlja zaostala vatrozidna pravila. Prekine li se skripta, elementi skupa svejedno isteknu djelovanjem jezgre, što je u svakom testu potvrđeno automatskim isticanjem blokade. Time se izbjegava slabost izvedbi u kojima prekid posrednika ostavlja mrežu u nedefiniranom stanju. Podrobnije obrazloženje dano je u poglavlju implementacije.

6.5.3. Izloženost nadzornih servisa

Tijekom skeniranja uočeno je da je na domaćinu 10.0.1.1 otvoren port 8086 (InfluxDB), dohvatljiv iz nadziranog segmenta. Nadzorni servisi (InfluxDB, Grafana) time čine dio površine napada vidljive klijentima, pa bi ih u stvarnoj primjeni trebalo izolirati od nadziranog segmenta. U radu je to kratko popravljeno ovom linijom u `docker-compose.yml`: "127.0.0.1:8086:8086" za InfluxDB odnosno "127.0.0.1:3000:3000" za Grafanu. Svi načini testiranja i mjerenja se mogu naći u dodatku `benchmark.sh`.

7. Zaključak i smjernice za daljnji rad

U radu je osmišljen i implementiran središnji sustav za nadzor i vizualizaciju komunikacijskih obrazaca lokalne mreže. Sustav pretvara uređaj s operacijskim sustavom Linux u jedinstveni operacijski centar koji istovremeno obavlja uloge usmjernika, bežične pristupne točke, mrežnog senzora i vatrozida, čime se sav promet lokalne mreže usmjerava kroz jednu točku i time postiže potpuna transparentnost komunikacije. Promet se pasivno analizira Zeekom na sučelju prije prevođenja adresa, pohranjuje u jedan od dvaju ispitanih podsustava i vizualizira u Grafani, dok se na temelju Zeekovih upozorenja provodi automatsko blokiranje izvorišnih adresa.

Glavnu ulogu u prilagodljivosti sustava ima Zeekov skriptni jezik. Detekcijska logika nije ograničena na konačnom skupu potpisa, nego se definira u datoteci `local.zeek` bez izmjene jezgre sustava, pa se pragovi, vremenski prozori i suzbijanje obavijesti prilagođavaju specifičnostima nadzirane mreže. Uz pomoć skriptnog jezika su napisani vlastiti detektori skeniranja portova i učestalosti SSH veza, dok su se pokazatelji kompromitacije priključili koristeći Intel okvir koji funkcionira neovisno o detekcijskoj logici. Upravo skriptni jezik, a ne pojedini ugrađeni mehanizam, čini sustav proširivim i prenosivim na druge obrasce prijetnji.

Naglasak rada nije na minimalnosti sklopovlja (iako se pokazalo kao nezaobilazna prepreka autoru) na kojem se rad izvodi, nego na cjelovitosti i automatiziranosti lanca detekcije i reakcije. Zabilježen je i opisan put od opažanja sumnjivih obrazaca ponašanja, evidencije tih obrazaca kroz `notice.log` zapis i reakcije kroz `auto_reaction.py` do izmjene članova u skupu `denylist` unutar `nftables` tablice koje se događa bez intervencije operatora. Dodatno, budući da trajanje blokade nameće vremensko ograničenje skupa kojim upravlja jezgra, a ne sama skripta, sustav je otporan na neplanirani prekid. Kontejnerizacija servisa i razdvajanje prikupljanja od pohrane montiranjem dijeljenog direktorija isključivo za čitanje čine arhitekturu prenosivom i neovisnom o konkretnom domaćinu. Demonstracija na potrošačkom prijenosnom računalu stoga pokazuje donju granicu zahtjeva sustava, a ne gornju granicu njegove primjenjivosti - isti se stog može prenijeti na snažniji domaćin bez izmjene detekcijske odnosno reakcijske logike pod uvjetom da se koristi Linux.

U skladu s time treba tumačiti i odabir baze InfluxDB iz poglavlja evaluacije. Taj odabir vrijedi za demonstrirani profil primjene, u kojem domaćin ograničenih resursa istovremeno obavlja više uloga, pa donja granica radne memorije postaje presudna. Budući da je sloj pohrane odvojen od prikupljanja, zamjena pozadinske baze drugim ispitanim podsustavom - Elasticsearchom, kada su presudni pretraga po sadržaju polja i korelacija više vrsta zapisa - svodi se na izmjenu konfiguracije, a ne na preinaku sustava. Mogućnost odabira između dvaju podsustava zato nije ograničenje, nego svojstvo arhitekture.

Smjernice za daljnji rad proizlaze iz ograničenja evidentiranih ovim radom. Mjerenja podsustava za pohranu provedena su na malenom skupu podataka, pa pouzdano govore o donjim granicama potrošnje, ali ne i o ponašanju pri znatnom rastu količine prometa. Mjerenja na većem skupu podataka, na kojima se očekuje izraženija prednost Elasticsearcha, ostaju prijedlog budućeg istraživačkog rada. Reakcija se oslanja na izvorišnu adresu iz zapisa upozorenja što predstavlja problem ako napadač krivotvori adresu izvora. Kao ublažavanje ovog problema predlaže se filtriranje na ulazu sučelja pristupne točke čime se odbacuju paketi izvan dodijeljenog adresnog prostora prije same detekcije (a posljedično i reakcije). Vidljivost prometa zaustavlja se pred šifriranim DNS-om (DoH i DoT), što ostaje poznata slijepa točka pasivnog nadzora. Detekcijsku je logiku moguće proširiti na dodatne vrste zapisa koje su u agentima pripremljene, ali namjerno isključene radi poštene usporedbe podsustava, pri čemu upravo skriptni jezik omogućuje izgradnju novih detektora nad tim zapisima. Dosadašnji se detektori oslanjaju na unaprijed zadane pragove i vremenske prozore, pa prepoznaju isključivo obrasce predviđene pravilima. Kako bi se izbjegle mane statičke detekcije, trenutni je stog moguće proširiti slojem koji obrasce prepoznaje uz pomoć modela strojnoga odnosno dubokoga učenja. Takav bi se model trenirao nad metapodacima koje Zeek prikuplja te bi, na temelju pojedinačnih veza ili skupina veza, zaključivao je li komunikacija zlonamjerna. Obrada bi se provodila na zahtjev operatora ili povremenim, nasumičnim uzorkovanjem parova adresa i njihove komunikacije, kako se resursi sustava ne bi nepotrebno trošili.

Naposljetku, zabilježena gornja granica pouzdanog hvatanja na korištenom sklopovlju ostaje smjernica za ispitivanje skaliranja, kao i razmatranje uporabe niskog kašnjenja upita za pravovremenu reakciju umjesto isključivo za osvježavanje nadzorne ploče.

Literatura

- [1] Splunk Inc., “Splunk enterprise documentation”, 2025., pristupljeno: 20.5.2026. [Mrežno]. Adresa: <https://docs.splunk.com/Documentation/Splunk>
- [2] Security Onion Solutions, “Security onion — intrusion detection, enterprise security monitoring, and log management”, 2025., pristupljeno: 20.5.2026. [Mrežno]. Adresa: <https://securityonionsolutions.com/software>
- [3] R. Bejtlich, *The Practice of Network Security Monitoring*. No Starch Press, 2013.
- [4] J. Malinen, “hostapd: Ieee 802.11 ap, ieee 802.1x/wpa/wpa2/eap/radius authenticator”, 2024., pristupljeno: 13.3.2026. [Mrežno]. Adresa: <https://w1.fi/hostapd/>
- [5] S. Kelley, “dnsmasq — a lightweight dhcp and caching dns server”, 2024., pristupljeno: 13.3.2026. [Mrežno]. Adresa: <https://dnsmasq.org>
- [6] Security Onion Solutions, “Security onion - hardware requirements”, 2026., pristupljeno: 21.5.2026. [Mrežno]. Adresa: <https://docs.securityonion.net/en/2.4/hardware.html>
- [7] Docker Inc., “Docker documentation”, 2025., pristupljeno: 1.6.2026. [Mrežno]. Adresa: <https://docs.docker.com>
- [8] InfluxData, “Influxdb 2.x documentation”, 2025., pristupljeno: 1.6.2026. [Mrežno]. Adresa: <https://docs.influxdata.com/influxdb/v2/>
- [9] —, “Get started with flux”, 2024., pristupljeno: 12.4.2026. [Mrežno]. Adresa: <https://docs.influxdata.com/flux/v0/get-started/>
- [10] —, “Flux query basics”, 2024., pristupljeno: 12.4.2026. [Mrežno]. Adresa: <https://docs.influxdata.com/flux/v0/get-started/query-basics/>
- [11] —, “Flux query language and influxdb basics”, 2024., pristupljeno: 12.4.2026. [Mrežno]. Adresa: <https://docs.influxdata.com/influxdb/v2/query-data/get-started/>

- [12] —, “Telegraf documentation”, 2025., pristupljeno: 1.6.2026. [Mrežno]. Adresa: <https://docs.influxdata.com/telegraf/v1/>
- [13] —, “Get started with telegraf”, 2025., pristupljeno: 12.4.2026. [Mrežno]. Adresa: <https://docs.influxdata.com/telegraf/v1/get-started/>
- [14] Elastic, “Elasticsearch documentation”, 2025., pristupljeno: 20.5.2026. [Mrežno]. Adresa: <https://www.elastic.co/docs/solutions/search>
- [15] —, “Filebeat reference”, 2025., pristupljeno: 29.5.2026. [Mrežno]. Adresa: <https://www.elastic.co/docs/reference/beats/filebeat>
- [16] Grafana Labs, “Grafana documentation”, 2025., pristupljeno: 10.5.2026. [Mrežno]. Adresa: <https://grafana.com/docs/grafana/latest/>
- [17] Y. Rekhter, R. G. Moskowitz, D. Karrenberg, G. J. de Groot, i E. Lear, “Address allocation for private internets”, RFC 1918, Internet Engineering Task Force (IETF), 1996., pristupljeno: 12.6.2026. [Mrežno]. Adresa: <https://www.rfc-editor.org/rfc/rfc1918>
- [18] The Zeek Project, “Zeek documentation”, 2025., pristupljeno: 1.6.2026. [Mrežno]. Adresa: <https://docs.zeek.org>
- [19] DeviWiki, “Tp-link tl-wn722n v1.x”, 2018., pristupljeno: 4.6.2026. [Mrežno]. Adresa: https://deviwiki.com/wiki/TP-LINK_TL-WN722N_v1.x
- [20] Arch Linux Wiki, “Software access point”, 2025., pristupljeno: 7.3.2026. [Mrežno]. Adresa: https://wiki.archlinux.org/title/Software_access_point

Skraćenice

AP	<i>Access Point</i>	pristupna točka
CCMP	<i>Counter Mode CBC-MAC Protocol</i>	protokol šifriranja unutar WPA2
CPU	<i>Central Processing Unit</i>	središnja procesorska jedinica
CSV	<i>Comma-Separated Values</i>	vrijednosti odvojene zarezom
DHCP	<i>Dynamic Host Configuration Protocol</i>	protokol za dinamičku dodjelu mrežnih postavki
DNS	<i>Domain Name System</i>	sustav imena domena
DoH	<i>DNS over HTTPS</i>	DNS preko HTTPS-a
DoT	<i>DNS over TLS</i>	DNS preko TLS-a
FTP	<i>File Transfer Protocol</i>	protokol za prijenos datoteka
HTTP	<i>HyperText Transfer Protocol</i>	protokol za prijenos hiperteksta
IEEE	<i>Institute of Electrical and Electronics Engineers</i>	Institut inženjera elektrotehnike i elektronike
ILM	<i>Index Lifecycle Management</i>	upravljanje životnim ciklusom indeksa (Elasticsearch)
IoC	<i>Indicator of Compromise</i>	pokazatelj kompromitacije
IoT	<i>Internet of Things</i>	internet stvari
IP	<i>Internet Protocol</i>	internetski protokol
ISP	<i>Internet Service Provider</i>	pružatelj internetskih usluga
JSON	<i>JavaScript Object Notation</i>	JavaScript objektna notacija
JVM	<i>Java Virtual Machine</i>	Java virtualni stroj
L2 / L3	<i>Layer 2 / Layer 3</i>	podatkovni / mrežni sloj (OSI model)
LAN	<i>Local Area Network</i>	lokalna mreža
MAC	<i>Media Access Control (address)</i>	adresa upravljanja pristupom mediju
NAT	<i>Network Address Translation</i>	prevođenje mrežnih adresa
NDJSON	<i>Newline Delimited JSON</i>	JSON sa zapisima odvojenima novim retkom
NSM	<i>Network Security Monitoring</i>	sigurnosni nadzor mreže
PSK	<i>Pre-Shared Key</i>	unaprijed dijeljeni ključ

QUIC	<i>Quick UDP Internet Connections</i>	brze UDP internetske veze
RADIUS	<i>Remote Authentication Dial-In User Service</i>	usluga udaljene autentifikacije korisnika
RAM	<i>Random Access Memory</i>	radna memorija
RFC	<i>Request for Comments</i>	niz dokumenata internetskih standarda
SOC	<i>Security Operations Center</i>	sigurnosno-operativni centar
SQL	<i>Structured Query Language</i>	strukturirani upitni jezik
SSH	<i>Secure Shell</i>	protokol za sigurnu udaljenu lju-sku
SSID	<i>Service Set Identifier</i>	identifikator bežične mreže
SSL	<i>Secure Sockets Layer</i>	sloj sigurnih utičnica
TCP	<i>Transmission Control Protocol</i>	protokol za upravljanje prijenosom
TLS	<i>Transport Layer Security</i>	sigurnost transportnog sloja
UDP	<i>User Datagram Protocol</i>	korisnički datagramski protokol
ufw	<i>Uncomplicated Firewall</i>	vatrozid na Linuxu
YAML	<i>YAML Ain't Markup Language</i>	jezik za serijalizaciju (konfigura-cijske datoteke)

Izjava o korištenju umjetne inteligencije

Prilikom izrade rada korišten je Anthropicov model Claude Sonnet 4.6. Model je korišten za ispravljanje bugova u konfiguracijskim datotekama, generiranje testnih skripti i refaktori-ranje alata kroz razvojni proces kako se rad gradio i kompleksnost povećavala.

Model nije dolazio do zaključaka niti su mu pruženi rezultati testova već kodovi greške s opisom prilikom implementacije i konfiguracije alata odnosno kontejnera. Također UI nije donosila izvršne zaključke rada niti je definirala tok kojim će se rad razvijati već su to radili autor ovog rada i njegov mentor.

Osvrt na korištenje umjetne inteligencije

Umjetna inteligencija uvelike pomaže pri "dosadnim" zadacima koji su prije bili nužni a sada se daju automatizirati - naravno do neke mjere. UI je uvelike pomogla pri pisanju konfiguracijskih datoteka koje su same po sebi suhoparne sa mnoštvom argumenata koje je potrebno razumijeti jako dobro kako bi sustav funkcionirao. Čak i pri pisanju konfiguracijskih datoteka potrebno je provjeriti izlaz modela jer to početno ponašanje sustava kasnije može diktirati tempo razvoja rada, takozvani tehnički dug. Osim konfiguracijskih skripti, model je pomagao pri pisanju postavljачkih shell skripti kako bi ispis bio bolji i kao provjeru razumnosti autoru. Sve te male stvari uštedjele su mnogo vremena te je osobno mišljenje autora da se umjetnoj inteligenciji treba pristupiti kao alatu koji sposobnim ljudima uvelike povećava efikasnost, a ne služi kao nešto čemu se slijepo vjeruje i na što se treba u potpunosti osloniti.

Izjava o korištenju umjetne inteligencije

Potvrđujem da sam tijekom izrade ovog diplomskog rada koristio umjetnu inteligenciju u skladu s Politikom primjerenog korištenja umjetne inteligencije na Fakultetu elektrotehnike i računarstva, te da umjetna inteligencija nije zamijenila moje kritičko razmišljanje niti moj doprinos.